

Федеральное государственное автономное образовательное учреждение
высшего образования "Национальный исследовательский университет
"Высшая школа экономики

Факультет компьютерных наук
Магистерская программа "Машинное обучение в цифровом продукте"

КУРСОВАЯ РАБОТА

На тему (рус.): Интерпретируемость больших языковых моделей

На тему (англ.): Interpretability of Large Language Models

Студент: _____

(Ф.И.О., подпись)

Руководитель КР: _____

(должность, звание, Ф.И.О.,
подпись)

Москва, 2026

Аннотация

В данной курсовой работе представлен подробный обзор методов механистической интерпретируемости нейронных сетей, основанный на трех ключевых публикациях. Рассматриваются: теория суперпозиции, объясняющая полисемантичность нейронов через оптимальное хранение разреженных признаков; метод разреженных автокодировщиков (SAE) для извлечения моносемантических признаков из активаций MLP-слоя; а также масштабирование SAE на промышленную языковую модель Claude 3 Sonnet с получением миллионов интерпретируемых признаков. Для каждого метода приводятся основная идея, ключевые формулы, алгоритм и результаты применения. Работа предназначена для исследователей в области безопасности и интерпретируемости больших языковых моделей.

Abstract

This paper provides a detailed survey of mechanistic interpretability methods for neural networks, drawing on three foundational publications. We review: the superposition hypothesis explaining neuronal polysemanticity; the sparse autoencoder (SAE) approach for decomposing language model activations into monosemantic features; and the scaling of SAEs to the production model Claude 3 Sonnet yielding millions of interpretable features. For each method, we present the core idea, key mathematical formulations, algorithmic details, and empirical results. The work is intended for researchers in the field of safety and interpretability of large language models.

Оглавление

Аннотация	1
Abstract	1
Введение	4
1 Обзор методов интерпретируемости	6
1.1 Суперпозиция в нейронных сетях	6
1.1.1 Понятие признака	6
1.1.2 Полисемантичесность нейронов	7
1.1.3 Гипотеза суперпозиции	7
1.1.4 Моносемантичесность как цель интерпретируемости . .	9
1.1.5 Вывод по разделу	9
1.2 SAE для поиска моносемантических признаков	10
1.2.1 Постановка задачи	10
1.2.2 Признаки как декомпозиция активаций	11
1.2.3 Архитектура SAE	11
1.2.4 Функция потерь	13
1.2.5 Процедура обучения	13
1.2.6 Метрики оценки	14
1.2.7 Найденные признаки	15
1.2.8 Анализ признаков	15
1.2.9 Выводы	16
1.3 Масштабирование SAE на промышленные LLM	16
1.3.1 Постановка эксперимента	17
1.3.2 Примеры найденных признаков	17
1.3.3 Управление поведением LLM через feature steering . .	19
1.3.4 Gemma Score: масштабирование на семейство Gemma 2	21
1.3.5 Qwen-Score: SAE для семейства Qwen	21
1.3.6 Ограничения	22
1.3.7 Выводы	23

Заключение	24
Библиографический список	26
А Глоссарий	28
В Исходные данные экспериментов	29
В.1 Протоколы	29
С Листинги кода (фрагменты)	30

Введение

Языковые модели, основанные на архитектуре трансформера [1], достигли выдающихся результатов во многих задачах обработки естественного языка. Такие модели, как GPT, Qwen, Deepseek и им подобные, способны генерировать связный текст, решать задачи и писать код. Вместе с тем их внутренние механизмы остаются в значительной мере непрозрачными: модель представляет собой миллиарды числовых параметров, не поддающихся непосредственному человеческому анализу.

Механистическая интерпретируемость ставит перед собой цель "реверс инжиниринга" нейронных сетей, то есть понимания конкретных вычислительных механизмов, лежащих в основе наблюдаемого поведения. Это направление приобретает особую важность в контексте безопасности ИИ: систематическое понимание того, как именно модель принимает решения, позволяет обнаруживать нежелательное поведение, проверять соответствие целям разработчиков и предсказывать возможные сбои.

В данной работе рассматриваются взаимосвязанные направления механистической интерпретируемости, представленные в трех публикациях исследовательской группы Anthropic:

1. **Toy Models of Superposition** [2] - теоретическая основа: почему нейроны языковых моделей полисемантичны и как явление суперпозиции объясняет эту полисемантичность на примере минималистичных игрушечных моделей.
2. **Towards Monosemanticity: Decomposing Language Models With Dictionary Learning** [3] - практический метод: разреженные автокодировщики (Sparse Autoencoders, SAE) для выделения интерпретируемых признаков из активаций MLP-слоев трансформера.
3. **Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet** [4] - масштабирование подхода на промышленную языковую модель, получение миллионов признаков и демонстрация их связи с вопросами безопасности.

Три работы образуют связную исследовательскую программу: от теоретического понимания суперпозиции - к практическому методу ее преодоления - к демонстрации, что этот метод работает на моделях класса frontier.

1 Обзор методов интерпретируемости

1.1 Суперпозиция в нейронных сетях

Данный раздел опирается на обзорную работу "Mechanistic Interpretability for AI Safety - A Review"[5] и основополагающую работу "Toy Models of Superposition"[2]. Вместе они формируют концептуальную базу всего направления механистической интерпретируемости, без которой невозможно понять ни метод разреженных автокодировщиков, ни масштабирование признаков на промышленные модели.

1.1.1 Понятие признака

По определению авторов [5], признак является фундаментальной единицей внутренних представлений нейронной сети, наименьшая независимо значимая единица, которую нельзя разложить на более простые независимые факторы.

Главная идея, объединяющая работы [2] и [5], — гипотеза линейного представления. Согласно ей, признаки, которые сеть научилась извлекать из данных, — это не отдельные нейроны, а векторы в пространстве активаций. Иными словами, признак кодируется не одним нейроном, а линейной комбинацией многих нейронов одновременно. Каждому признаку i сопоставляется единичный вектор $\mathbf{f}_i \in \mathbb{R}^n$ в пространстве активаций $\mathbb{R}^n$, а "присутствие" признака в данном входе $\mathbf{x}$ выражается скалярным произведением $\langle \mathbf{x}, \mathbf{f}_i \rangle$.

Косвенным свидетельством в пользу этой гипотезы служит векторная арифметика в пространствах эмбедингов для word2vec [6], например, king — man + woman $\approx$ queen.

Важно различать нейрон и признак. Нейрон - конкретная вычислительная единица сети, одна координата в пространстве активаций. Признак - абстрактная единица, соответствующая некоторому вектору в этом же пространстве. В идеальном случае каждый нейрон соответствует ровно одному признаку. На практике это утверждение нарушается.

1.1.2 Полисемантичность нейронов

Полисемантичность - свойство нейрона активироваться на несколько семантически несвязанных признаков [5]. Полисемантический нейрон реагирует на разные, внешне не связанные входные данные, например, один и тот же нейрон может активироваться на упоминания столиц, на арабские символы и на фрагменты кода, признаки с совершенно разными смыслами.

Полисемантичность особенно выражена в трансформерных моделях и является главной проблемой в механистической интерпретируемости, зная активацию нейрона, невозможно однозначно установить, какой именно признак закодирован в данном конкретном контексте.

Причины полисемантичности. В статье [5] выделяют три конкурирующие гипотезы:

1. Несовпадение признаков с базисом нейронов, т.е. в архитектурах без структурно привилегированного базиса нет оснований ожидать совпадения признаков с осями нейронов. Полисемантичность в таком случае неизбежна независимо от числа признаков.
2. Методы регуляризации, например, dropout, распределяют представление одного признака по нескольким нейронам, добавляя полисемантичности.
3. Суперпозиция(основная гипотеза) - число признаков в данных существенно превышает число нейронов сети. В такой ситуации модель вынуждена сжимать несколько признаков в один и тот же набор нейронов.

1.1.3 Гипотеза суперпозиции

Гипотеза суперпозиции [2] утверждает: нейронные сети представляют больше признаков, чем имеют нейронов, кодируя эти признаки в виде комбинаций нейронных активаций.

Игрушечная модель. В статье [2] авторы исследуют минималистичную модель, в которой d разреженных входных признаков сжимаются в $n < d$ нейронов и восстанавливаются обратно:

$$\mathbf{h} = \mathbf{W}\mathbf{x}, \quad \mathbf{x}' = \text{ReLU}(\mathbf{W}^\top \mathbf{h} + \mathbf{b}), \quad (1.1)$$

где $\mathbf{W} \in \mathbb{R}^{n \times d}$ - матрица проекции, $\mathbf{x} \in \mathbb{R}^d$ - входной вектор (d признаков), $\mathbf{h} \in \mathbb{R}^n$ - сжатое скрытое представление (n нейронов).

Функция потерь взвешивает ошибки восстановления по важности признаков:

$$\mathcal{L} = \sum_{\mathbf{x}} \sum_{i=1}^d a_i (x_i - x'_i)^2, \quad (1.2)$$

где $a_i > 0$ — важность i -го признака.

Основные результаты игрушечной модели. Эксперименты с этой моделью демонстрируют качественный переход:

- **Без суперпозиции:** сеть хранит ограниченное число признаков, представляя каждый строго вдоль одного нейрона; остальные признаки игнорируются.
- **С суперпозицией:** сеть "упаковывает" значительно больше признаков, чем нейронов, размещая их в почти ортогональных суперпозициях за счет малой вероятности одновременной активации.

Привилегированный и непривилегированный базисы. Важным концептом является тип базиса представления [5]:

- **Привилегированный базис** формируется элементами, выделяющими конкретные направления, например, нелинейными активациями ReLU. В таком базисе признаки могут совпасть с направлениями нейронов, что способствует моносемантичности.
- **Непривилегированный базис** - пространство, в котором модель не выделяет никаких конкретных направлений. Признаки не обязаны

совпадать с осями нейронов, поэтому полисемантичность является неизбежной.




Рис. 1. Визуализация привилегированного и непривилегированного базисов, моносемантических и полисемантических нейронов

1.1.4 Моносемантичность как цель интерпретируемости

Моносемантичность - свойство нейрона соответствовать только одному семантическому признаку [5]. Моносемантический нейрон однозначно интерпретируем: его активация свидетельствует о наличии конкретного признака.

В полностью моносемантической нейронной сети задача механистической интерпретируемости сводилась бы к описанию каждого нейрона.

Полисемантический нейрон можно представить как сжатую проекцию нескольких нейронов гипотетической более широкой сети, в которой каждый нейрон соответствовал бы ровно одному признаку. На самом деле обученная сеть, ограниченная в числе нейронов, проецирует это моносемантическое пространство в меньшую размерность, порождая полисемантичность. Задача методов интерпретируемости - обратить эту проекцию и восстановить исходное пространство признаков. Именно эту цель преследует метод разреженных автокодировщиков (SAE), рассматриваемый в следующем разделе.

1.1.5 Вывод по разделу

Понятие признака как вектора активаций и явление суперпозиции образуют фундамент для механистической интерпретируемости. Полисеман-

тичность нейронов является ожидаемым следствием обучения: число признаков сильно превышает число нейронов, и сеть вынуждена сжимать.

Моносеманτικότητα, напротив, представляет собой идеальное состояние - ситуацию "один нейрон, один признак при которой интерпретация нейронной сети становится решаемой. Необходимы методы, способные "распутать" суперпозицию и извлечь однозначные признаки из наблюдаемых активаций. Эту задачу решают разреженные автокодировщики (SAE), которым посвящен следующий раздел.

1.2 SAE для поиска моносемантических признаков

В работе "Towards Monosemanticity: Decomposing Language Models With Dictionary Learning"[3] авторы предложили метод, направленный на решение проблемы полисемантической нейронов языковых моделей с помощью SAE (разреженных автокодировщиков).

1.2.1 Постановка задачи

Рассматривается однослойный трансформер с размером модели 512, обученный на корпусе The Pile [7]. Объектом анализа является выход MLP слоя, вектор $\mathbf{x} \in \mathbb{R}^n$, где $n = 512$.

Целью является разложить выход MLP слоя на признаки, количество которых больше числа нейронов. Задача состоит в том, чтобы получить словарь признаков, в идеальном случае полученный словарь будет содержать моносемантические нейроны, соответствующие признакам. Для поиска такого разреженного представления применяется SAE (разреженный автокодировщик).




Рис. 2. Применение SAE к выходу MLP-слоя однослойного трансформера.

1.2.2 Признаки как декомпозиция активаций

Прежде чем перейти к архитектуре SAE, авторы вводят понятие хорошей декомпозиции. Декомпозиция активаций является качественной, если:

1. восстановленные активации $\hat{\mathbf{x}}$ близки к исходным $\mathbf{x}$
2. среднее число ненулевых признаков на токен мало
3. каждый найденный признак активируется на семантически схожем множестве токенов и поддается человеческому пониманию
4. признаки, найденные при разных запусках обучения, похожи друг на друга

1.2.3 Архитектура SAE

SAE состоит из энкодера и декодера с общим скрытым пространством размерности m .

Энкодер принимает вектор активаций $\mathbf{x} \in \mathbb{R}^n$, вычитает смещение декодера и применяет преобразование с функцией активации ReLU:

$$\mathbf{f}(\mathbf{x}) = \text{ReLU}(\mathbf{W}_{\text{enc}}(\mathbf{x} - \mathbf{b}_{\text{dec}}) + \mathbf{b}_{\text{enc}}), \quad (1.3)$$

где $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{m \times n}$ - матрица весов энкодера, $\mathbf{b}_{\text{enc}} \in \mathbb{R}^m$ - смещение энкодера, $\mathbf{b}_{\text{dec}} \in \mathbb{R}^n$ - смещение декодера (вычитается до кодирования), а $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^m$ - вектор активаций признаков.

Декодер восстанавливает исходный вектор из активаций признаков:

$$\hat{\mathbf{x}} = \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) + \mathbf{b}_{\text{dec}}, \quad (1.4)$$

где $\mathbf{W}_{\text{dec}} \in \mathbb{R}^{n \times m}$.




Рис. 3. Архитектура разреженного автокодировщика (SAE).

Также применяется два приема, которые сильно влияют на качество разложения и интерпретируемость признаков

- Перед подачей активационного вектора в энкодер из него вычитается смещение $\mathbf{b}_{\text{dec}}$, которое равно среднему значению MLP активаций. Такое преобразование позволяет убрать постоянную составляющую и в энкодере использовать только на отклонения от среднего, т.к. они несут информацию
- ReLU обнуляет отрицательные активации, обеспечивая неотрицательность $\mathbf{f}(\mathbf{x})$ и вводя разреженность, следовательно в реконструкции участвуют только часть признаков.

1.2.4 Функция потерь

SAE обучается минимизировать функцию потерь:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{ошибка реконструкции}} + \lambda \underbrace{\|\mathbf{f}(\mathbf{x})\|_1}_{\text{штраф за плотность}}, \quad (1.5)$$

где $\lambda > 0$ - коэффициент регуляризации, отвечающий за баланс между качеством реконструкции и разреженностью активаций признаков.

Ошибка реконструкции (L_2) заставляет SAE восстанавливать исходные активации, но если бы SAE обучалось только на такую функцию потерь, то модель не смогла бы получать разреженные представления.

L_1 -штраф штрафует за сумму абсолютных значений активаций признаков, что и заставляет вектор активаций признаков быть разреженным.

Роль гиперпараметра λ :

- При малом λ SAE точно восстанавливает $\mathbf{x}$, но признаки плотные и плохо интерпретируемые
- При большом λ , признаки разреженные, но реконструкция неточная, теряется часть информации исходных активаций

1.2.5 Процедура обучения

SAE обучается на активациях, собранных заранее при прогоне однослойного трансформера на случайных токенах из корпуса The Pile [7] - открытого датасета объемом > 800 ГБ, включающий в себя разнообразные тексты на разных языках. Обучение SAE ведется уже на активациях уже обученной LLM.

Авторы обучают SAE с различными коэффициентами расширения m/n : $1\times$, $2\times$, $4\times$, $8\times$, $16\times$, $32\times$ относительно $n = 512$. Это дает словари от 512 до 16384 признаков. Основные результаты получены на словаре $m = 4096$ ($8\times$).

В процессе обучения часть признаков может так и не начать активироваться, т.е. появятся "мертвые" признаки. Это происходит из-за того, что

градиент через неактивные нейроны ReLU равен нулю. Авторы используют эвристику периодической переинициализации "мертвых" признаков, которая помогает задействовать неиспользуемые признаки.

1.2.6 Метрики оценки

Для оценки качества обученного SAE обычно используют следующие методы.

Оценка качества реконструкции

- **L_2 -ошибка** - среднеквадратическое отклонение восстановленных активаций от исходных
- **Доля объясненных потерь** (fraction of loss recovered): насколько использование $\hat{\mathbf{x}}$ вместо $\mathbf{x}$ изменяет cross-entropy loss LLM. Если подставить реконструкции SAE обратно в модель вместо исходных активаций MLP, деградация потерь показывает, сколько информации утеряно при кодировании.

Оценка разреженности

- **L_0 -норма** - среднее число ненулевых активаций $f_i(\mathbf{x})$ на токен. Т.е. чем меньше, тем более разреженным является представление.
- **L_1 -норма**: ограничивает сумму абсолютных значений активаций признаков

Оценка интерпретируемости

Для автоматизации применяют LLM-as-a-Judge [8]:

1. Для признака i отбираются k токенов с наибольшей активацией
2. Языковая модель генерирует лэйбл, описание признака
3. На отдельной выборке из k' токенов LLM просят предсказать, будет ли признак активен для каждого токена;

4. Вычисляются доля правильно определенных активаций

1.2.7 Найденные признаки

Словарь из 4096 признаков ($8\times$ увеличение) содержит разнообразные интерпретируемые концепты: числовые (*base-10 digits, decimal fractions*), биологические (*DNA sequences, periodic table elements*), лингвистические (*Hebrew, Cyrillic, Arabic script*), связанные с кодом (*function arguments, Python imports*) и академические (*citations, Bible quotations*).

Ключевой результат: признаки SAE значительно более моносемантичны, чем исходные нейроны - наиболее активирующие токены каждого признака принадлежат одной семантической категории, следовательно такие признаки можно описать каким-то лэйблом.

1.2.8 Анализ признаков

Помимо анализа отдельных признаков, авторы исследуют свойства полученного словаря.

Дробление признаков

При увеличении размера словаря от $1\times$ до $32\times$ наблюдается дробление признаков: признак, представлявший в малом словаре широкую концепцию, в большем словаре разбивается на несколько более специфических подпризнаков. Например:

- Словарь 512: один признак "числа";
- Словарь 4096: признаки "арабские числа" "числа в скобках" "числа в десятичных дробях" "числа в временных обозначениях" и т.д.

Дробление свидетельствует о том, что SAE выявляет иерархическую структуру признакового пространства и что большие словари действительно "открывают" новые, более тонкие различия.

Универсальность признаков

Сравнение признаков, выученных в разных запусках SAE (с различными инициализациями и разными коэффициентами расширения), показывает высокую степень воспроизводимости. Признаки, найденные в одном словаре, имеют хорошо выраженный "двойник" в другом словаре.

"Мертвые" признаки

Часть признаков остается "мертвой" т.е. никогда не активируются. При $8\times$ увеличении доля "мертвых" признаков составляет порядка 20-30%. Авторы интерпретируют это как ограничение текущего метода обучения, а не как свидетельство того, что в активациях нет дополнительных структур.

1.2.9 Выводы

Работа "Towards Monosemanticity" вносит существенный вклад в механистическую интерпретируемость, демонстрируя:

1. Разреженные автокодировщики позволяют декомпонировать полисемантические нейронные активации в более интерпретируемое пространство моносемантических признаков
2. Функция потерь (1.5) обеспечивает баланс между точностью реконструкции и разреженностью при контролируемом λ
3. Увеличение размера словаря приводит к дроблению признаков и росту интерпретируемости
4. Автоматическая оценка интерпретируемости с помощью LLM позволяет масштабировать анализ на тысячи признаков.

1.3 Масштабирование SAE на промышленные LLM

Проверив гипотезы на игрушечной модели, модели с одним трансформерным блоком, можно переходить на промышленные LLM, в данном

разделе больше внимание будет уделено работе "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet"[4], но также затроним работы связанные с другими моделями, такими как Qwen и Gemma.

1.3.1 Постановка эксперимента

В исследовании [4] эксперименты проводились на Claude 3 Sonnet, LLM с многомиллиардным числом параметров. SAE применяется к выходу трансформерного блока из середины сети.

Авторы [4] используют ту же базовую архитектуру SAE с ReLU и L1, что и в [3]. Обучали SAE трех размеров: 1 048 576 ($\approx 1M$), 4 194 304 ($\approx 4M$) и 33 554 432 ($\approx 34M$) признаков. SAE обучался на активациях, собранных на внутреннем датасете Anthropic. Для визуализации найденных признаков использовались два открытых датасета: The Pile (без подмножества books3) [7] и Common Crawl [9]. Полученные после всех трех SAE реконструкции объясняли не менее 65% дисперсии активаций моделей, а доля мертвых признаков варьировалось от 2% до 65% в зависимости от размера словаря признаков.

1.3.2 Примеры найденных признаков

"Golden Gate Bridge"

Один из наиболее известных примеров статьи - признак, соответствующий признаку относящемуся к "Golden Gate Bridge". Признак активируется одновременно на:

- текстовые упоминания моста в любом контексте
- изображения моста
- смежные признаки - Сан-Франциско, мосты и т.д.

Для проверки авторы применили **feature steering**, усиление признака в ≈ 20 раз, что приводило к тому, что модель начинала ассоциировать себя как мост в ответ на любой запрос. При отключении признака эффект полностью исчезал. Подробное описание метода — в подразделе 1.3.3.




Рис. 4. Пример признака "Golden Gate Bridge" с увеличенной активацией.

Признаки, связанные с безопасностью

Авторы [4] обнаружили ряд признаков, потенциально связанных с безопасностью модели. Но важное замечание, существование такого признака не означает, что модель ведет себя опасно, необходимо отличать знание о вредоносном поведении и его воспроизведение. Следовательно наличие и активность этих признаков позволяет контролировать такое поведение.

Выявлено три признака, связанных с уязвимостями:

- признак "unsafe code активирующийся на уязвимости в системе безопасности и не только
- признак "code error реагирующий на баги и исключения
- признак "backdoor"

Например, принудительная активация признака небезопасного кода приводит к тому, что модель генерирует код с утечками памяти, тогда как при нормальной работе она этого не делает.

Также были обнаружены признаки, активирующиеся на расистские, сексистские и другие поведения. Один из примеров, признак гендерного неравенства в профессиях, пример текстов на которых активируется такой признак - соотношение мужчин и женщин среди медсестер или профессоров. Также были найдены признаки, связанные с ненавистью и оскорблениями, принудительная активация с увеличением в 20 раз заставляет модель генерировать расистские высказывания.

Выявлена группа признаков, связанных с разными формами "угодливости" такие как признак эмпатии и солидарности "yeah, me too" признак

лести и признак саркастических похвал. Принудительная активация признака лести с увеличением в 5 раз заставляет модель хвалить пользователя по любому поводу.

Обнаружение подобных признаков в промышленных LLM важно для исследований безопасности, они позволяют проверять, при каких условиях эти признаки активируются, и изучать их вклад в поведение модели и возможности исключения соответствующего поведения.

1.3.3 Управление поведением LLM через feature steering

Работа [4] идет дальше простой детекции признаков и показывает, что при помощи SAE можно менять поведение модели.

Feature steering - метод целенаправленного изменения поведения языковой модели путем вмешательства в активации отдельных признаков SAE во время инференса. Вместо того чтобы воздействовать на веса модели или промпт, можно усиливать или подавлять конкретный признак, меняя поведение модели, добиваясь желаемого поведения. Есть много вариаций feature steering, но в статье [4] используется метод Activation Clamping:

Activation Clamping. Активация признака j принудительно фиксируется на заданном уровне c независимо от входа:

$$f_j(\mathbf{x}) \leftarrow c. \quad (1.6)$$




Рис. 5. Схема метода feature steering: принудительная фиксация активации признака SAE изменяет поведение модели.

Так, например, признак "Golden Gate Bridge" усиливался в ≈ 20 раз относительно средней активации (подраздел 1.3.2). Модель начинала описывать себя как мост в ответ на любой запрос. Эффект полностью пропал при отключении признака - это подтверждает работу метода Activation Clamping.

Ограничения метода. При умеренных Feature steering стабилен и поведение изменяется предсказуемо. При слишком больших s есть вероятность

достаточно сильно испортить модель и получить непредсказуемое поведение.

1.3.4 Gemma Score: масштабирование на семейство Gemma 2

В работе "Gemma Score"[10] метод SAE применяется к семейству моделей Gemma 2 (2B, 9B, 27B), при этом обучаются SAE для каждого слоя каждой модели. Обучались SAE с размерами словаря от 16 384 до 1 048 576 признаков.

Вместо функции активации с ReLU и L1-штрафом авторы предлагают JumpReLU - функцию активации с обучаемым порогом θ :

$$f_i(\mathbf{x}) = \text{ReLU}(z_i - \theta_i) \cdot \mathbf{1}[z_i > \theta_i], \quad z_i = (\mathbf{W}_{\text{enc}} \mathbf{x} + \mathbf{b}_{\text{enc}})_i, \quad (1.7)$$

где порог θ_i обучается отдельно для каждого признака. При использовании L1-штрафа активации признаков оказываются искусственно заниженными, штраф за ненулевые значения вынуждает модель уменьшать их даже тогда, когда признак действительно активен. JumpReLU делает так, что признак либо полностью зануляется, если активация ниже порога θ_i , либо активируется без какого-либо занижения.

1.3.5 Qwen-Score: SAE для семейства Qwen

В работа "Qwen-Score"[11] авторы применяют SAE к моделям Qwen. Вместо L1-штрафа используют Топ-К активации, на каждый токен остаются активными ровно k признаков с наибольшими преактивациями, остальные обнуляются. Значение k фиксировано во время обучения ($k = 50$ или $k = 100$). Это гарантирует постоянный уровень разреженности без подбора гиперпараметра λ . Ширина словаря признаков составляла $16\times$ от размерности модели. Ключевой практический результат работы - метод SASFT (Sparse Autoencoder-guided Supervised Fine-Tuning), использование признаков SAE в процессе дообучения модели.



Рис. 6. Пример code-switching

Стандартный SFT обучает модель выдавать желаемые результаты, не вмешиваясь во внутренние представления о мире. SASFT дополняет его вспомогательной функцией потерь, которая штрафует активацию конкретных признаков SAE, связанных с нежелательным поведением.

Проблема code-switching - нежелательное переключение языка внутри ответа, например, модель отвечает на китайском, когда вопрос задан на английском. Авторы предлагают на корпусе проблемных примеров с переключением языка отбирать признаки SAE с наибольшей активацией, найти среди них специфичные для языка признаки. Затем при дообучении к стандартной функции потерь добавить слагаемое, минимизирующее активации найденных признаков на нежелательных примерах. Таким образом модель учится одновременно давать правильные ответы и подавлять активность проблемных признаков.

Такой подход снизил частоту code-switching на 50% [11]. При этом такого рода вмешательства затрагивают только целевые признаки. SASFT демонстрирует, что SAE - не только инструмент анализа, но и инструмент для улучшения поведения модели или же получения определенного поведения.

1.3.6 Ограничения

При недостаточном размере словаря SAE может сжимать два коррелирующих признака в один, признак A оказывается закодирован не отдельно, а только в связке $A + B$. Это нарушает моносемантичность и затрудняет интерпретацию.

Масштабирование словаря признаков привести к значительным уве-

личениями требований к памяти. Например, матрица энкодера SAE с 16М признаков при размерности модели $d = 4096$ имеет размер $W_{\text{enc}} \in \mathbb{R}^{16,000,000 \times 4096}$, что в формате float16 занимает ≈ 250 ГБ - больше, чем весит сама языковая модель. Это делает инференс с SAE затруднителен без специальных методов и квантизации.

1.3.7 Выводы

В рассмотренных статьях можно выделить несколько ключевых направлений.

Во-первых, feature steering, [4] исследователи из Anthropic обнаружили признаки, связанные с опасным поведением модели: бэкдоры в коде, сексизм и т.д. . Так принудительная активация признака бэкдора заставляет модель писать вредоносный код, активация признака угодливости - хвалить пользователя за любую глупость. Это значит, что мониторинг активаций таких признаков во время инференса - потенциально рабочий способ раннего обнаружения опасного поведения.

Во-вторых, обе последующие работы предложили альтернативные функции активации. Gemma Scope [10] ввёл JumpReLU (1.7) с обучаемым порогом, Qwen-Score [11] - Top-K с фиксированным числом активных признаков. Оба подхода решают одну проблему, L1-штраф занижает амплитуду активных признаков, искажая их интерпретацию.

В-третьих, Qwen-Score предложил SASFT - метод, в котором сигналы SAE встраиваются непосредственно в процесс дообучения. Вместо того чтобы только наблюдать за признаками, авторы используют их для дополнения к функции потерь. На практике это позволило снизить частоту нежелательного переключения языка на 50%, не меняя остального поведения модели.

Заключение

В данной курсовой работе рассмотрена серия из трех взаимосвязанных работ, образующих последовательную исследовательскую программу в области механистической интерпретируемости языковых моделей.

Достигнутые результаты.

- Изучена теоретическая основа полисемантической нейронов - **гипотеза суперпозиции** [2]: нейронные сети хранят больше признаков, чем имеют нейронов, кодируя их в почти ортогональных векторах. Показано возникновение правильных геометрических конфигураций суперпозиции и введено различие привилегированных и непривилегированных базисов.
- Подробно разобран метод **разреженных автокодировщиков** [3]: архитектура SAE (1.3)–(1.4), функция потерь (1.5) с L1-регуляризацией, система оценки признаков через ручную и автоматизированную интерпретируемость, а также каузальная верификация через feature steering.
- Проанализировано **масштабирование метода** [4]: архитектура ReLU + L1 с взвешиванием штрафа по норме декодера, законы масштабирования (??), обнаружение признаков безопасности и мультимодальных концептов в Claude 3 Sonnet при размере словаря до 16М признаков.

Значимость подхода. Три рассмотренные работы показывают: *механистическая интерпретируемость масштабируемых языковых моделей достижима*. SAE позволяет преобразовать непрозрачные активации в словарь интерпретируемых признаков, сохраняя точность описания вычислений. Обнаружение признаков, связанных с безопасностью (prompt injection, манипуляция, нежелательный контент), непосредственно применимо для аудита и верификации безопасного поведения моделей.

Перспективы. Среди открытых задач - систематическая каузальная верификация признаков, разработка теоретических гарантий восстановления "истинных" признаков и снижение вычислительной стоимости методов для промышленного применения.

Библиографический список

1. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. — 2017. — Т. 30. — URL: <https://arxiv.org/abs/1706.03762>.
2. Toy Models of Superposition / N. Elhage [и др.] // Transformer Circuits Thread. — 2022. — URL: https://transformer-circuits.pub/2022/toy_model/index.html.
3. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning / T. Bricken [и др.] // Transformer Circuits Thread. — 2023. — URL: <https://transformer-circuits.pub/2023/monosemantic-features/index.html>.
4. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet / A. Templeton [и др.] // Transformer Circuits Thread. — 2024. — URL: <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>.
5. *Bereska L., Gavves E.* Mechanistic Interpretability for AI Safety — A Review // arXiv preprint arXiv:2404.14082. — 2024. — URL: <https://arxiv.org/abs/2404.14082>.
6. Efficient Estimation of Word Representations in Vector Space / T. Mikolov [и др.] // arXiv preprint arXiv:1301.3781. — 2013. — URL: <https://arxiv.org/abs/1301.3781>.
7. The Pile: An 800GB Dataset of Diverse Text for Language Modeling / L. Gao [и др.] // arXiv preprint arXiv:2101.00027. — 2020. — URL: <https://arxiv.org/abs/2101.00027>.
8. A Survey on LLM-as-a-Judge / J. Gu [и др.] // arXiv preprint arXiv:2411.15594. — 2024. — URL: <https://arxiv.org/abs/2411.15594>.
9. *Common Crawl Foundation.* Common Crawl. — 2024. — URL: <https://commoncrawl.org>.

10. Gemma Scope: Open Sparse Autoencoders Everywhere All At Once on Gemma 2 / Т. Lieberum [и др.] // arXiv preprint arXiv:2408.05147. — 2024. — URL: <https://arxiv.org/abs/2408.05147>.
11. *Qwen Team*. Qwen-Scope: Turning Sparse Features into Development Tools for Large Language Models // arXiv preprint arXiv:2605.11887. — 2026. — URL: <https://arxiv.org/abs/2605.11887>.

Терминологический словарь

Overfitting Переобучение модели.

Regularization Регуляризация.

В Исходные данные экспериментов

В.1 Протоколы

Текст протоколов.

С Листинги кода (фрагменты)

```
import numpy as np
def loss(y_true, y_pred):
    return np.mean((y_true - y_pred)**2)
```