

Федеральное государственное автономное образовательное учреждение
высшего образования "Национальный исследовательский университет
"Высшая школа экономики

Факультет компьютерных наук
Магистерская программа "Машинное обучение в цифровом продукте"

КУРСОВАЯ РАБОТА

На тему (рус.): Интерпретируемость больших языковых моделей

На тему (англ.): Interpretability of Large Language Models

Студент: _____

(Ф.И.О., подпись)

Руководитель КР: _____

(должность, звание, Ф.И.О.,
подпись)

Москва, 2026

Аннотация

В данной курсовой работе представлен подробный обзор методов механистической интерпретируемости нейронных сетей, основанный на трех ключевых публикациях. Рассматриваются: теория суперпозиции, объясняющая полисемантичность нейронов через оптимальное хранение разреженных признаков; метод разреженных автокодировщиков (SAE) для извлечения моносемантических признаков из активаций MLP-слоя; а также масштабирование SAE на промышленную языковую модель Claude 3 Sonnet с получением миллионов интерпретируемых признаков. Для каждого метода приводятся основная идея, ключевые формулы, алгоритм и результаты применения. Работа предназначена для исследователей в области безопасности и интерпретируемости больших языковых моделей.

Abstract

This paper provides a detailed survey of mechanistic interpretability methods for neural networks, drawing on three foundational publications. We review: the superposition hypothesis explaining neuronal polysemanticity; the sparse autoencoder (SAE) approach for decomposing language model activations into monosemantic features; and the scaling of SAEs to the production model Claude 3 Sonnet yielding millions of interpretable features. For each method, we present the core idea, key mathematical formulations, algorithmic details, and empirical results. The work is intended for researchers in the field of safety and interpretability of large language models.

Оглавление

Аннотация	1
Abstract	1
Введение	4
1 Обзор методов интерпретируемости	6
1.1 Суперпозиция в нейронных сетях	6
1.1.1 Понятие признака	6
1.1.2 Полисемантичесность нейронов	7
1.1.3 Гипотеза суперпозиции	7
1.1.4 Моносемантичесность как цель интерпретируемости . .	9
1.1.5 Вывод по разделу	9
1.2 Разреженные автокодировщики для поиска моносемантических признаков	10
1.2.1 Мотивация: проблема полисемантичесности	10
1.2.2 Гипотеза суперпозиции	10
1.2.3 Постановка задачи	11
1.2.4 Признаки как декомпозиция активаций	12
1.2.5 Архитектура разреженного автокодировщика	12
1.2.6 Функция потерь	14
1.2.7 Процедура обучения	15
1.2.8 Метрики оценки	16
1.2.9 Результаты: найденные признаки	17
1.2.10 Глобальный анализ	19
1.2.11 Феноменология признаков	20
1.2.12 Каузальное вмешательство в активации признаков . .	21
1.2.13 Интерфейс для анализа признаков	22
1.2.14 Обсуждение и ограничения	22
1.2.15 Выводы по методу	23
1.3 Масштабирование SAE: признаки Claude 3 Sonnet	24

1.3.1	Масштаб и задача	24
1.3.2	Архитектура	24
1.3.3	Законы масштабирования для SAE	25
1.3.4	Примеры найденных признаков	25
1.3.5	Признаки как вычислительные промежуточные	27
1.3.6	Самопредставление модели	27
1.3.7	Универсальность признаков	28
1.3.8	Ограничения и открытые вопросы	28
1.3.9	Выводы по масштабированию	29
Заключение		30
Библиографический список		32
А Глоссарий		33
В Исходные данные экспериментов		34
В.1	Протоколы	34
С Листинги кода (фрагменты)		35

Введение

Языковые модели, основанные на архитектуре трансформера [1], достигли выдающихся результатов во многих задачах обработки естественного языка. Такие модели, как GPT, Qwen, Deepseek и им подобные, способны генерировать связный текст, решать задачи и писать код. Вместе с тем их внутренние механизмы остаются в значительной мере непрозрачными: модель представляет собой миллиарды числовых параметров, не поддающихся непосредственному человеческому анализу.

Механистическая интерпретируемость ставит перед собой цель "реверс инжиниринга" нейронных сетей, то есть понимания конкретных вычислительных механизмов, лежащих в основе наблюдаемого поведения. Это направление приобретает особую важность в контексте безопасности ИИ: систематическое понимание того, как именно модель принимает решения, позволяет обнаруживать нежелательное поведение, проверять соответствие целям разработчиков и предсказывать возможные сбои.

В данной работе рассматриваются взаимосвязанные направления механистической интерпретируемости, представленные в трех публикациях исследовательской группы Anthropic:

1. **Toy Models of Superposition** [2] - теоретическая основа: почему нейроны языковых моделей полисемантичны и как явление суперпозиции объясняет эту полисемантичность на примере минималистичных игрушечных моделей.
2. **Towards Monosemanticity: Decomposing Language Models With Dictionary Learning** [3] - практический метод: разреженные автокодировщики (Sparse Autoencoders, SAE) для выделения интерпретируемых признаков из активаций MLP-слоев трансформера.
3. **Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet** [4] - масштабирование подхода на промышленную языковую модель, получение миллионов признаков и демонстрация их связи с вопросами безопасности.

Три работы образуют связную исследовательскую программу: от теоретического понимания суперпозиции - к практическому методу ее преодоления - к демонстрации, что этот метод работает на моделях класса frontier.

1 Обзор методов интерпретируемости

1.1 Суперпозиция в нейронных сетях

Данный раздел опирается на обзорную работу "Mechanistic Interpretability for AI Safety - A Review"[5] и основополагающую работу "Toy Models of Superposition"[2]. Вместе они формируют концептуальную базу всего направления механистической интерпретируемости, без которой невозможно понять ни метод разреженных автокодировщиков, ни масштабирование признаков на промышленные модели.

1.1.1 Понятие признака

По определению авторов [5], признак является фундаментальной единицей внутренних представлений нейронной сети, наименьшая независимо значимая единица, которую нельзя разложить на более простые независимые факторы.

Главная идея, объединяющая работы [2] и [5], — гипотеза линейного представления. Согласно ей, признаки, которые сеть научилась извлекать из данных, — это не отдельные нейроны, а векторы в пространстве активаций. Иными словами, признак кодируется не одним нейроном, а линейной комбинацией многих нейронов одновременно. Каждому признаку i сопоставляется единичный вектор $\mathbf{f}_i \in \mathbb{R}^n$ в пространстве активаций $\mathbb{R}^n$, а "присутствие" признака в данном входе $\mathbf{x}$ выражается скалярным произведением $\langle \mathbf{x}, \mathbf{f}_i \rangle$.

Косвенным свидетельством в пользу этой гипотезы служит векторная арифметика в пространствах эмбедингов для word2vec [6], например, king — man + woman $\approx$ queen.

Важно различать нейрон и признак. Нейрон - конкретная вычислительная единица сети, одна координата в пространстве активаций. Признак - абстрактная единица, соответствующая некоторому вектору в этом же пространстве. В идеальном случае каждый нейрон соответствует ровно одному признаку. На практике это утверждение нарушается.

1.1.2 Полисемантичность нейронов

Полисемантичность - свойство нейрона активироваться на несколько семантически несвязанных признаков [5]. Полисемантический нейрон реагирует на разные, внешне не связанные входные данные, например, один и тот же нейрон может активироваться на упоминания столиц, на арабские символы и на фрагменты кода, признаки с совершенно разными смыслами.

Полисемантичность особенно выражена в трансформерных моделях и является главной проблемой в механистической интерпретируемости, зная активацию нейрона, невозможно однозначно установить, какой именно признак закодирован в данном конкретном контексте.

Причины полисемантичности. В статье [5] выделяют три конкурирующие гипотезы:

1. Несовпадение признаков с базисом нейронов, т.е. в архитектурах без структурно привилегированного базиса нет оснований ожидать совпадения признаков с осями нейронов. Полисемантичность в таком случае неизбежна независимо от числа признаков.
2. Методы регуляризации, например, dropout, распределяют представление одного признака по нескольким нейронам, добавляя полисемантичности.
3. Суперпозиция(основная гипотеза) - число признаков в данных существенно превышает число нейронов сети. В такой ситуации модель вынуждена сжимать несколько признаков в один и тот же набор нейронов.

1.1.3 Гипотеза суперпозиции

Гипотеза суперпозиции [2] утверждает: нейронные сети представляют больше признаков, чем имеют нейронов, кодируя эти признаки в виде комбинаций нейронных активаций.

Игрушечная модель. В статье [2] авторы исследуют минималистичную модель, в которой d разреженных входных признаков сжимаются в $n < d$ нейронов и восстанавливаются обратно:

$$\mathbf{h} = \mathbf{W}\mathbf{x}, \quad \mathbf{x}' = \text{ReLU}(\mathbf{W}^\top \mathbf{h} + \mathbf{b}), \quad (1.1)$$

где $\mathbf{W} \in \mathbb{R}^{n \times d}$ - матрица проекции, $\mathbf{x} \in \mathbb{R}^d$ - входной вектор (d признаков), $\mathbf{h} \in \mathbb{R}^n$ - сжатое скрытое представление (n нейронов).

Функция потерь взвешивает ошибки восстановления по важности признаков:

$$\mathcal{L} = \sum_{\mathbf{x}} \sum_{i=1}^d a_i (x_i - x'_i)^2, \quad (1.2)$$

где $a_i > 0$ — важность i -го признака.

Основные результаты игрушечной модели. Эксперименты с этой моделью демонстрируют качественный переход:

- **Без суперпозиции:** сеть хранит ограниченное число признаков, представляя каждый строго вдоль одного нейрона; остальные признаки игнорируются.
- **С суперпозицией:** сеть "упаковывает" значительно больше признаков, чем нейронов, размещая их в почти ортогональных суперпозициях за счёт малой вероятности одновременной активации.

Привилегированный и непривилегированный базисы. Важным концептом является тип базиса представления [5]:

- **Привилегированный базис** формируется элементами, выделяющими конкретные направления, например, нелинейными активациями ReLU. В таком базисе признаки могут совпасть с направлениями нейронов, что способствует моносемантичности.
- **Непривилегированный базис** - пространство, в котором модель не выделяет никаких конкретных направлений. Признаки не обязаны

совпадать с осями нейронов, поэтому полисемантичность является неизбежной.

1.1.4 Моносемантичность как цель интерпретируемости

Моносемантичность - свойство нейрона соответствовать только одному семантическому признаку [5]. Моносемантичный нейрон однозначно интерпретируем: его активация свидетельствует о наличии конкретного признака.

В полностью моносемантичной нейронной сети задача механистической интерпретируемости сводилась бы к описанию каждого нейрона.

Полисемантичный нейрон можно представить как сжатую проекцию нескольких нейронов гипотетической более широкой сети, в которой каждый нейрон соответствовал бы ровно одному признаку. На самом деле обученная сеть, ограниченная в числе нейронов, проецирует это моносемантичное пространство в меньшую размерность, порождая полисемантичность. Задача методов интерпретируемости - обратить эту проекцию и восстановить исходное пространство признаков. Именно эту цель преследует метод разреженных автокодировщиков (SAE), рассматриваемый в следующем разделе.

1.1.5 Вывод по разделу

Понятие признака как вектора активаций и явление суперпозиции образуют фундамент для механистической интерпретируемости. Полисемантичность нейронов является ожидаемым следствием обучения: число признаков сильно превышает число нейронов, и сеть вынуждена сжимать.

Моносемантичность, напротив, представляет собой идеальное состояние - ситуацию "один нейрон, один признак при которой интерпретация нейронной сети становится решаемой. Необходимы методы, способные "распутать" суперпозицию и извлечь однозначные признаки из наблюдаемых активаций. Эту задачу решают разреженные автокодировщики (SAE), которым посвящён следующий раздел.

1.2 Разреженные автокодировщики для поиска моносемантических признаков

Данный раздел посвящен методу, предложенному в работе Bricken et al. [3] "Towards Monosemanticity: Decomposing Language Models With Dictionary Learning" (Anthropic, 2023). Метод направлен на решение фундаментальной проблемы механистической интерпретируемости - полисемантической нейронов языковых моделей - с помощью разреженных автокодировщиков (Sparse Autoencoder, SAE).

1.2.1 Мотивация: проблема полисемантической

Центральная проблема механистической интерпретируемости состоит в том, что нейроны нейронных сетей, как правило, являются **полисемантическими**: один нейрон активируется на несколько семантически несвязанных концепций. Авторы приводят наглядный пример из однослойного трансформера: нейрон 2 049 MLP-слоя сильно активируется на токены, относящиеся к академическим цитатам, переводам, фрагментам прозы в кавычках, обозначениям времени в японском тексте и последовательностям ДНК - совершенно разнородный набор концепций.

Такая полисеманτικότητα существенно затрудняет интерпретацию: даже если исследователь изучает активацию отдельного нейрона, он не может установить, какой именно концепт этот нейрон "видит" в конкретном контексте.

Ключевой гипотезой, объясняющей это явление, служит **гипотеза суперпозиции**.

1.2.2 Гипотеза суперпозиции

Гипотеза суперпозиции [2] утверждает, что нейронные сети представляют *больше признаков*, чем у них имеется нейронов, кодируя эти признаки через линейные комбинации нейронов. Это возможно, если выполняются два условия:

- **Разреженность признаков:** каждый признак активен лишь на малой доле входных данных, поэтому вероятность одновременной активации двух "соседних" признаков невелика;
- **Приблизительная ортогональность:** признаки кодируются в направлениях, которые примерно ортогональны друг другу, что минимизирует взаимную интерференцию.

Игрушечная модель суперпозиции [2] демонстрирует: при обучении линейной сети с n нейронами представлять $m > n$ разреженных признаков сеть "упаковывает" все признаки в суперпозицию, жертвуя точностью, но выигрывая в емкости. Форма хранения зависит от соотношения m/n и уровня разреженности: при высокой разреженности признаки образуют примерно правильные многогранники в n -мерном пространстве.

Таким образом, полисемантичность нейронов является *не случайным артефактом обучения*, а предсказуемым следствием суперпозиции: нейрон одновременно участвует в представлении нескольких признаков.

1.2.3 Постановка задачи

Авторы исследуют **однослойный трансформер** с 512-мерным пространством активаций ($d = 512$), обученный на корпусе The Pile [7]. Объектом анализа служат **post-ReLU активации MLP-слоя**: вектор $\mathbf{x} \in \mathbb{R}^n$, где $n = 512$ - число нейронов в расширенном пространстве MLP ($d_{\text{MLP}} = 4d = 2048$, но авторы обозначают анализируемое измерение через n).

Задача формулируется следующим образом: найти **словарь признаков** из $m \gg n$ элементов - набор направлений $\{\mathbf{d}_i\}_{i=1}^m$ в пространстве $\mathbb{R}^n$ - такой, что каждый вектор активаций $\mathbf{x}$ может быть приближенно представлен через небольшое число активных признаков:

$$\mathbf{x} \approx \mathbf{b}_{\text{dec}} + \sum_{i=1}^m f_i(\mathbf{x}) \cdot \mathbf{d}_i, \quad (1.3)$$

где $f_i(\mathbf{x}) \geq 0$ - скалярное значение активации i -го признака, $\mathbf{b}_{\text{dec}}$ - смещение, и при этом большинство $f_i(\mathbf{x})$ равны нулю (разреженность).

1.2.4 Признаки как декомпозиция активаций

Прежде чем перейти к архитектуре SAE, авторы формализуют понятие **хорошей декомпозиции**. Согласно статье, декомпозиция активаций является качественной, если:

1. **Точность**: восстановленные активации $\hat{\mathbf{x}}$ близки к исходным $\mathbf{x}$ (малая ошибка реконструкции);
2. **Разреженность**: среднее число ненулевых признаков на токен (L_0 -норма) мало - в идеале от 1 до нескольких десятков;
3. **Интерпретируемость**: каждый найденный признак активируется на семантически однородном множестве токенов и поддается человеческому объяснению;
4. **Универсальность**: признаки, найденные независимыми запусками обучения, воспроизводят друг друга (т.е. не являются артефактами конкретной инициализации).

Авторы обосновывают, почему нельзя использовать отдельные нейроны как "признаки": полисемантичность означает, что направление нейрона не соответствует ни одной интерпретируемой концепции. PCA и ICA также не подходят: главные компоненты не разрежены и не соответствуют семантическим концептам. Кластеризация не применима, поскольку один токен может активировать несколько признаков одновременно. Метод NMF требует неотрицательности исходных данных. Оптимальным решением оказывается **разреженное кодирование** на переполненном (overcomplete) словаре.

1.2.5 Архитектура разреженного автокодировщика

SAE состоит из энкодера и декодера с общим промежуточным пространством размерности m .

Энкодер. Энкодер принимает вектор активаций $\mathbf{x} \in \mathbb{R}^n$, вычитает декодерное смещение и применяет аффинное преобразование с функцией активации ReLU:

$$\mathbf{f}(\mathbf{x}) = \text{ReLU}(\mathbf{W}_{\text{enc}} (\mathbf{x} - \mathbf{b}_{\text{dec}}) + \mathbf{b}_{\text{enc}}), \quad (1.4)$$

где $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{m \times n}$ - матрица весов энкодера, $\mathbf{b}_{\text{enc}} \in \mathbb{R}^m$ - смещение энкодера, $\mathbf{b}_{\text{dec}} \in \mathbb{R}^n$ - смещение декодера (вычитается до кодирования), а $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^m$ - вектор активаций признаков.

Декодер. Декодер линейно восстанавливает исходный вектор из активаций признаков:

$$\hat{\mathbf{x}} = \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) + \mathbf{b}_{\text{dec}}, \quad (1.5)$$

где $\mathbf{W}_{\text{dec}} \in \mathbb{R}^{n \times m}$. Столбцы матрицы декодера обозначаются $\mathbf{d}_i \in \mathbb{R}^n$ и называются **атомами словаря** (dictionary atoms): каждый $\mathbf{d}_i$ задает направление i -го признака в пространстве активаций.

Ограничение на норму. Принципиальным архитектурным решением является требование **единичной нормы** столбцов декодера:

$$\|\mathbf{d}_i\|_2 = 1 \quad \forall i \in \{1, \dots, m\}. \quad (1.6)$$

Это ограничение предотвращает вырожденное решение, при котором декодерные веса уменьшаются до нуля, а энкодер компенсирует это произвольно большими активациями. Нормировка обеспечивает, что каждый атом словаря является *единичным направлением*, а масштабная информация полностью сосредоточена в значениях $f_i(\mathbf{x})$.

Дизайнерские решения.

- **Pre-bias subtraction (вычитание смещения до кодирования).**

Декодерное смещение $\mathbf{b}_{\text{dec}}$ аппроксимирует среднее значение вектора активаций по всему датасету. Вычитая его перед кодированием, авторы центрируют данные относительно их среднего, позволяя энкодеру фокусироваться на отклонениях от среднего - именно они несут структурированную семантическую информацию.

- **Отсутствие разделения весов (no weight tying).** В отличие от классических автокодировщиков, где $\mathbf{W}_{\text{enc}} = \mathbf{W}_{\text{dec}}^\top$, в SAE $\mathbf{W}_{\text{enc}}$ и $\mathbf{W}_{\text{dec}}$ полностью независимы. Это позволяет энкодеру и декодеру использовать различные геометрические представления одного и того же пространства признаков.
- **ReLU как механизм разреженности.** Функция ReLU обнуляет отрицательные активации, обеспечивая неотрицательность $\mathbf{f}(\mathbf{x})$ и вводя неявную разреженность: лишь те признаки, у которых предактивационное значение положительно, участвуют в реконструкции.

1.2.6 Функция потерь

SAE обучается минимизировать следующую функцию потерь:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{ошибка реконструкции}} + \lambda \underbrace{\|\mathbf{f}(\mathbf{x})\|_1}_{\text{штраф за плотность}}, \quad (1.7)$$

где $\lambda > 0$ - коэффициент регуляризации, управляющий компромиссом между точностью реконструкции и разреженностью активаций признаков.

Ошибка реконструкции (L_2). Первое слагаемое принуждает SAE точно восстанавливать исходные активации. Если бы оно было единственным, модель свелась бы к полному представлению $\mathbf{x}$ через $\mathbf{f}(\mathbf{x})$ без каких-либо ограничений разреженности.

L_1 -штраф. Второе слагаемое штрафует за сумму абсолютных значений активаций признаков, поощряя решения, в которых большинство $f_i(\mathbf{x})$ равны нулю. Норма L_1 является **выпуклой релаксацией** нормы L_0 (числа ненулевых компонент) и при этом остается дифференцируемой, что допускает обучение градиентными методами.

Роль гиперпараметра λ .

- При малом λ : SAE точно восстанавливает $\mathbf{x}$, но признаки плотные и плохо интерпретируемые;

- При большом λ : признаки разреженные, но реконструкция неточная (теряется часть информации об активациях);
- Оптимальное λ находится эмпирически, ориентируясь на метрики интерпретируемости и качества реконструкции.

Полная функция потерь, усредненная по батчу токенов:

$$\mathcal{L} = \mathbb{E}_{\mathbf{x}} \left[\|\mathbf{x} - \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) - \mathbf{b}_{\text{dec}}\|_2^2 + \lambda \sum_{i=1}^m f_i(\mathbf{x}) \right]. \quad (1.8)$$

1.2.7 Процедура обучения

Данные. SAE обучается на активациях, собранных заранее при прогоне однослойного трансформера на случайных токенах из корпуса The Pile [7] - открытого датасета объемом ~ 800 ГБ, охватывающего широкий спектр текстовых жанров и языков. Обучение SAE ведется отдельно от обучения языковой модели - на зафиксированных активациях.

Размеры словарей. Авторы обучают семейство SAE с различными коэффициентами расширения m/n : $1\times$, $2\times$, $4\times$, $8\times$, $16\times$, $32\times$ относительно $n = 512$. Это дает словари от 512 до 16 384 признаков. Основные результаты получены на словаре $m = 4096$ ($8\times$).

Оптимизация. Используется оптимизатор Adam. Нормировка столбцов декодера поддерживается на каждом шаге через проецирование градиента: после шага оптимизатора все столбцы $\mathbf{d}_i$ нормируются на единичную длину, что реализует ограничение (1.6).

"Мертвые" признаки. В процессе обучения часть признаков может так и не начать активироваться ("мертвые" признаки, dead features). Это происходит из-за того, что градиент через неактивные нейроны ReLU равен нулю. Авторы используют эвристику периодической переинициализации мертвых признаков, которая помогает задействовать неиспользуемые атомы словаря.

1.2.8 Метрики оценки

Авторы предлагают комплексную систему оценки качества обученного SAE.

Качество реконструкции

- **L_2 -ошибка:** $\mathbb{E}[\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2]$ - среднеквадратическое отклонение восстановленных активаций от исходных.
- **Доля объясненных потерь** (fraction of loss recovered): насколько использование $\hat{\mathbf{x}}$ вместо $\mathbf{x}$ изменяет cross-entropy потери языковой модели. Если подставить реконструкции SAE обратно в модель вместо исходных активаций MLP, деградация потерь показывает, сколько информации утеряно при кодировании.

Разреженность

- **L_0 -норма:** среднее число ненулевых активаций $f_i(\mathbf{x})$ на токен. Является прямой мерой разреженности: чем меньше, тем более сжатым является представление. Для словаря 4 096 признаков авторы достигают $L_0 \approx 25$ - в среднем на токен активируется лишь 25 из 4096 признаков ($\approx 0.6\%$).
- **L_1 -норма:** $\mathbb{E}[\|\mathbf{f}(\mathbf{x})\|_1]$ - используется в функции потерь, менее информативна для интерпретации.

Интерпретируемость

Это наиболее важная и нетривиальная метрика, для оценки которой авторы разработали двухуровневый подход.

Ручная оценка. Исследователи изучают каждый признак вручную:

1. Отбираются токены с наибольшей активацией $f_i(\mathbf{x})$ (топ-10–20 по значению);
2. Выводится контекст каждого токена (окно в 20–30 символов);

3. Исследователь формулирует гипотезу о том, что именно активирует признак;
4. Гипотеза проверяется на случайных токенах с высокой активацией.

Автоматическая интерпретируемость. Авторы применяют языковую модель (GPT-4 или Claude) для автоматизации процесса:

1. Для данного признака i отбираются k токенов с наибольшей активацией (положительные примеры) и k токенов с нулевой активацией (отрицательные примеры);
2. Языковая модель генерирует *объяснение* - гипотезу о семантике признака;
3. На отдельной выборке из k' токенов (удерживаемой выборке) языковую модель просят предсказать, будет ли признак активен для каждого токена;
4. Вычисляются **detection score** (доля правильно угаданных активаций) и **false positive rate** (доля ложноположительных срабатываний).

Чем выше detection score при низком false positive rate, тем более точным и специфичным является объяснение признака.

1.2.9 Результаты: найденные признаки

Словарь из 4 096 признаков (8×-расширение) демонстрирует богатое разнообразие интерпретируемых концептов. Авторы описывают подробно несколько категорий.

Базовые числовые признаки.

- *Base-10 digits*: активируется на цифры 0–9 вне зависимости от контекста;

- *Arabic numerals in non-Latin scripts*: арабские числа, встречающиеся внутри текстов на нелатинских системах письма (например, в персидских или арабских текстах);
- *Numbers in decimal fractions*: числа, выступающие в роли дробной части десятичной записи.

Биологические и научные признаки.

- *DNA sequences*: активируется на токены внутри последовательностей нуклеотидов (ATCG...); является одним из наиболее часто цитируемых примеров в статье как демонстрация специфичности найденных признаков;
- *Periodic table elements*: символы химических элементов;
- *Mathematical notation*: математические символы и обозначения.

Лингвистические признаки.

- *Hebrew text*: токены в тексте на иврите;
- *Arabic script*: арабское письмо;
- *Cyrillic text*: кириллица;
- *Legal language*: юридические термины и формулировки.

Программный код.

- *Function arguments*: имена аргументов функций в коде;
- *Variable assignment*: оператор присваивания в различных языках программирования;
- *Python import statements*: инструкции импорта в Python.

Академический и публикационный стиль.

- *Academic citations*: токены в академических ссылках (например, "et al. "ibid. номера страниц в скобках);
- *Bible quotations*: фрагменты библейских текстов;
- *Prose quotations*: цитаты в художественных текстах.

Авторы подчеркивают: признаки, выявленные SAE, *значительно более моносемантчны*, чем исходные нейроны. Большинство топ-активирующих токенов для каждого признака относятся к семантически однородной категории, и эксперты-люди без труда формулируют объяснение.

1.2.10 Глобальный анализ

Помимо анализа отдельных признаков, авторы исследуют глобальные свойства выученного словаря.

Распределение частот активации

Частота активации признаков ($\rho_i = P(f_i(\mathbf{x}) > 0)$) распределена приближенно по степенному закону: большинство признаков редкие ($\rho_i < 0.1\%$), и лишь немногие активируются на значительной доле токенов. Такое распределение согласуется с предположением о разреженности: признаки соответствуют специфическим концептам, которые встречаются в тексте нечасто.

Дробление признаков (Feature Splitting)

При увеличении размера словаря от $1\times$ до $32\times$ наблюдается **дробление признаков**: признак, представлявший в малом словаре широкую концепцию, в большем словаре разбивается на несколько более специфических подпризнаков. Например:

- Словарь 512: один признак "числа";

- Словарь 4 096: признаки "арабские числа" "числа в скобках" "числа в десятичных дробях" "числа в временных обозначениях" и т. д.

Дробление свидетельствует о том, что SAE выявляет иерархическую структуру признакового пространства и что большие словари действительно "открывают" новые, более тонкие различия.

Универсальность признаков (Feature Universality)

Сравнение признаков, выученных в разных запусках SAE (с различными инициализациями и разными коэффициентами расширения), показывает высокую степень **воспроизводимости**. Признаки, найденные в одном словаре, имеют хорошо выраженный "двойник" в другом словаре (высокая косинусная близость атомов $\mathbf{d}_i$). Это говорит о том, что признаки отражают реальную структуру активационного пространства, а не являются артефактами конкретного обучения.

"Мертвые" признаки

Часть атомов словаря остается "мертвой" (dead features) - никогда не активируется в течение оценочного периода. При 8×-расширении доля мертвых признаков составляет порядка 20–30%. Авторы интерпретируют это как ограничение текущего метода обучения, а не как свидетельство того, что в активациях нет дополнительных структур.

1.2.11 Феноменология признаков

Авторы проводят детальный анализ нескольких признаков, демонстрируя типичный паттерн. Для каждого признака строится:

- **Гистограмма активаций**: крайне правостороннее распределение - большинство токенов дают нулевую активацию, и лишь единичные токены показывают высокие значения;
- **Scatter-plot**: активации на осях двух признаков (показывает слабую корреляцию между признаками - признак независимости);

- **Список топ-токенов:** контексты с наибольшей активацией, позволяющие оценить семантику признака;
- **Список анти-токенов:** контексты с наиболее отрицательным преактивационным значением (до ReLU) - то, что "противоположно" признаку.

Анализ подтверждает: признаки с высоким detection score имеют четкую семантику, однородные топ-токены и статистически значимую отделимость от фона.

1.2.12 Каузальное вмешательство в активации признаков

Одним из ключевых вопросов является: *являются ли найденные признаки реальными вычислительными единицами, влияющими на поведение модели?* Корреляция признака с токенами еще не означает каузальности.

Для ответа авторы проводят **интервенционные эксперименты** (feature steering):

1. Выбирается признак i с известной семантикой;
2. При прогоне токена t активация признака искусственно фиксируется: $f_i(\mathbf{x}) \leftarrow c$ (где c значительно превышает естественный уровень);
3. Наблюдается изменение распределения следующего токена (вывода модели).

Результаты показывают, что принудительная активация признака вызывает *предсказуемое и семантически согласованное* изменение вывода. Например, активация признака "DNA sequences" побуждает модель генерировать нуклеотидные последовательности. Это подтверждает, что найденные признаки - не просто корреляты, а **каузально значимые вычислительные единицы** языковой модели.

1.2.13 Интерфейс для анализа признаков

Авторы создают **интерактивный веб-интерфейс** для просмотра обученных признаков. Интерфейс позволяет:

- Просматривать топ-токены для каждого признака;
- Искать признаки по ключевым словам (например, ввести "DNA" и найти соответствующий признак);
- Изучать корреляции между признаками;
- Видеть предсказания автоматической интерпретируемости.

Доступность такого инструмента существенно упрощает дальнейшие исследования и проверку интерпретируемости.

1.2.14 Обсуждение и ограничения

Масштабируемость

Основным ограничением работы является масштаб: SAE обучается на *однослойном* трансформере с 512-мерными активациями. Применение метода к современным многослойным моделям (например, GPT-4 или Claude с тысячами измерений) требует значительно большего вычислительного ресурса и может потребовать новых архитектурных решений.

"Является ли контекст признаком?"

Авторы обсуждают философский вопрос: некоторые "признаки" кодируют не столько семантику *токена*, сколько *контекст*. Например, признак может активироваться не на сам токен "ATCG" а на любой токен в тексте, содержащем последовательность ДНК. Это разграничение важно для понимания того, что именно представляют признаки - локальную или глобальную информацию.

Дополнительные свойства.

- **Признаки сами могут быть полисемантическими:** в малых словарях один признак объединяет семантически различные, но статистически коррелирующие концепты. Дробление при увеличении словаря частично решает эту проблему.
- **Влияние на кросс-энтропию:** подстановка реконструкций SAE вместо исходных активаций увеличивает кросс-энтропийные потери языковой модели, что указывает на неизбежные потери информации при сжатии. Авторы показывают, что большие словари дают меньшие потери.
- **Связь с нейронауками:** метод разреженного кодирования восходит к классической модели Olshausen & Field [8] представления зрительной коры V1 через разреженный базис, что придает подходу дополнительную биологическую мотивацию.

1.2.15 Выводы по методу

Работа "Towards Monosemanticity" вносит существенный вклад в механистическую интерпретируемость, демонстрируя:

1. Разреженные автокодировщики позволяют декомпозировать полисемантические нейронные активации в более интерпретируемое пространство моносемантических признаков;
2. Функция потерь (1.7) обеспечивает баланс между точностью реконструкции и разреженностью при контролируемом λ ;
3. Выученные признаки каузально влияют на поведение модели (feature steering);
4. Увеличение размера словаря приводит к дроблению признаков и росту интерпретируемости;
5. Автоматическая оценка интерпретируемости с помощью языковых моделей позволяет масштабировать анализ на тысячи признаков.

1.3 Масштабирование SAE: признаки Claude 3 Sonnet

Данный раздел посвящен работе Templeton et al. [4] "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet"(Anthropic, 2024). Она масштабирует подход SAE с однослойного трансформера на промышленную языковую модель и демонстрирует, что интерпретируемость достижима при миллионах признаков.

1.3.1 Масштаб и задача

Эксперименты проводились на **Claude 3 Sonnet** - фронтальной языковой модели с многомиллиардным числом параметров. SAE применялся к **residual stream** после 16-го трансформерного блока (из 48), с размерностью $d = 4096$.

Диапазон словарей: $M \in \{1K, 4K, 16K, 65K, 262K, 1M, 4M, 16M\}$. Для обучения использовалось 4×10^9 токенов - смесь английского, многоязычного и кодового контента.

1.3.2 Архитектура

Авторы [4] используют ту же базовую архитектуру ReLU + L1, что и в [3]. Активации нормируются предварительно: их средняя квадратичная L_2 -норма приводится к размерности D остаточного потока. Функция потерь:

$$\mathcal{L} = \mathbb{E}_{\mathbf{x}} \left[\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 + \lambda \sum_i f_i(\mathbf{x}) \|W_{:,i}^{\text{dec}}\|_2 \right], \quad (1.9)$$

где L1-штраф **взвешивается нормой соответствующего декодерного вектора**, а не является просто суммой активаций. Единичная нормировка декодерных векторов при этом не накладывается. Авторы отмечают, что это ключевое улучшение, снижающее артефакты обучения.

Ограничение: shrinkage. L1-штраф имеет известный недостаток - **shrinkage**: систематическое занижение амплитуд активных признаков. Авторы признают это открытой проблемой и указывают, что параллельные работы

предлагают альтернативы - в частности, Rajamanoharan et al. вводят JumpReLU-активацию с обучаемым порогом, а Wright & Sharkey - подход на основе дообучения.

1.3.3 Законы масштабирования для SAE

Авторы обнаруживают, что качество SAE описывается **степенным законом**:

$$\mathcal{L}_{\text{recon}}(M) \propto M^{-\alpha}, \quad \alpha \approx 0.5\text{--}0.7, \quad (1.10)$$

то есть ошибка реконструкции убывает по степенному закону от размера словаря - аналогично законам масштабирования для самих языковых моделей. Это означает, что каждое удвоение словаря приносит предсказуемое уменьшение ошибки.

CE loss gap. Практически важнейшая метрика - **Cross-Entropy loss gap**: насколько деградируют предсказания языковой модели, если заменить ее внутренние активации на реконструированные из SAE. При $M \approx 1\text{M}$ признаков разрыв становится пренебрежимо малым, то есть SAE практически полностью описывает вычисления модели.

Feature splitting. При увеличении M наблюдается **расщепление признаков**: крупный признак (например, "код на Python") разделяется на более тонкие ("функции Python" "классы Python" "импорты Python"). Это отражает реальную иерархическую структуру данных, а не артефакт обучения.

1.3.4 Примеры найденных признаков

"Мост Золотые Ворота"

Один из наиболее известных примеров статьи - признак, соответствующий концепту "Мост Золотые Ворота" (Golden Gate Bridge). Примечательно его мультимодальное поведение: признак активируется одновременно

на:

- текстовые упоминания моста в любом контексте;
- изображения моста (в мультимодальных промптах);
- метафорические употребления ("мост между культурами");
- смежные концепты - Сан-Франциско, подвесные мосты.

Для проверки каузальности авторы провели **эксперимент по управлению** (steering): искусственная активация признака с амплитудой $\alpha \gg 0$:

$$\mathbf{x}' = \mathbf{x} + \alpha \cdot \mathbf{d}_j, \quad (1.11)$$

где $\mathbf{d}_j$ - направление признака в residual stream. При высоком α модель начинала неуместно упоминать мост в любом контексте и описывала себя как мост - демонстрируя прямое каузальное влияние признака на поведение.

Признаки, связанные с безопасностью

Особую практическую значимость имеет обнаружение признаков, релевантных для задач безопасности:

- **Prompt injection**: признак активируется на попытки встроить скрытые инструкции во входные данные.
- **Манипуляция и обман**: признак на контексты, содержащие манипулятивные паттерны.
- **Нежелательный контент**: кластер признаков, связанных с потенциально вредоносными темами.
- **Угодливость (sycophancy)**: признаки на паттерны чрезмерного согласия с пользователем.

Обнаружение этих признаков открывает возможности для целенаправленного аудита: вместо случайного red-teaming можно напрямую проверить, при каких условиях активируются потенциально опасные признаки, и отследить их причинно-следственные эффекты на поведение модели.

Признаки личностей и абстрактных концептов

SAE выявил признаки для более 400 известных личностей - ученых, политиков, писателей - каждый из которых активируется на имя, связанные события и биографические факты данного человека.

Обнаружен признак "синдрома самозванца психологически тонкий концепт, активирующийся на контексты неуверенности в собственной компетентности, что демонстрирует способность SAE извлекать понятия высокого уровня абстракции.

1.3.5 Признаки как вычислительные промежуточные

Работа [4] идет дальше простой детекции признаков и показывает, что признаки SAE участвуют в **вычислительных цепочках** внутри модели.

Пример: географический вывод. При обработке токена "Берлин" прослеживается цепочка:

"Берлин" $\rightarrow$ признак "немецкий город" $\rightarrow$ признак "столица" $\rightarrow$ усиление п...

Метод проверки. Для верификации каузальной цепочки используется **activation patching**: активация признака j в слое l заменяется на активацию из другого примера, и наблюдается изменение финального предсказания. Если признак каузально значим - замена изменит предсказание предсказуемым образом.

1.3.6 Самопредставление модели

Среди найденных признаков - признаки, связанные с тем, как модель **представляет саму себя**:

- Признак "Claude identity": активируется при упоминании имени модели и при рефлексивных вопросах о ее природе.
- Признаки ограничений и возможностей: кодируют, что модель считает допустимым или недопустимым.

- Признаки ролевой структуры диалога: "Assistant" "User" системный промпт.

Интересно, что признаки самоидентификации Claude пространственно близки к признакам ограничений безопасности - это согласуется с гипотезой, что RLHF встраивает концепцию безопасного поведения в "самопредставление" модели.

1.3.7 Универсальность признаков

Авторы проверяют, воспроизводятся ли признаки, найденные в одной модели, в других. Результаты:

- Большинство высокоуровневых семантических признаков (личности, концепты, синтаксические паттерны) воспроизводятся во всех трех моделях семейства Claude 3 (Haiku, Sonnet, Opus), что указывает на их связь со структурой обучающих данных, а не с конкретной архитектурой.
- Признаки сохраняются при RLHF fine-tuning: настройка меняет *веса* признаков в вычислениях, но не их *направления* в пространстве активаций.

1.3.8 Ограничения и открытые вопросы

Проблема валидации

Не существует строгого критерия, позволяющего убедиться, что найденные признаки являются "истинными" вычислительными объектами модели, а не артефактами SAE. Ablation и steering дают каузальные свидетельства, но применялись лишь к малой доле признаков.

Полнота

Малый CE loss gap гарантирует точность *реконструкции*, но не то, что SAE интерпретирует *все* функционально значимые паттерны. Часть вычислений может быть закодирована нелинейно - вне линейной модели признаков.

Feature absorption

При недостаточном размере словаря SAE может "поглощать" два коррелирующих признака в один: признак A оказывается закодирован не отдельно, а только в связке $A + B$. Это нарушает моносемантичесность и затрудняет интерпретацию.

Вычислительная стоимость

Матрица $W_{\text{enc}} \in \mathbb{R}^{16\text{M} \times 4096}$ требует ≈ 250 ГБ памяти в float16. Inference SAE добавляет $\mathcal{O}(M \cdot d)$ операций на каждый токен, что существенно при промышленном развертывании.

1.3.9 Выводы по масштабированию

Работа "Scaling Monosemanticity" демонстрирует:

1. Метод SAE масштабируется на промышленные LLM: при $M \approx 1\text{M}$ признаков CE loss gap становится пренебрежимо малым.
2. Качество реконструкции подчиняется степенному закону (1.10), что позволяет предсказывать и планировать масштабирование.
3. Среди признаков обнаруживаются объекты, непосредственно важные для задач безопасности (prompt injection, манипуляция, опасный контент).
4. Признаки являются каузально значимыми вычислительными объектами: их управление через steering влечет предсказуемые изменения поведения.
5. Топ-К активация превосходит L1-регуляризацию по качеству и удобству управления.

Заключение

В данной курсовой работе рассмотрена серия из трех взаимосвязанных работ, образующих последовательную исследовательскую программу в области механистической интерпретируемости языковых моделей.

Достигнутые результаты.

- Изучена теоретическая основа полисемантической нейронов - **гипотеза суперпозиции** [2]: нейронные сети хранят больше признаков, чем имеют нейронов, кодируя их в почти ортогональных векторах. Показано возникновение правильных геометрических конфигураций суперпозиции и введено различие привилегированных и непривилегированных базисов.
- Подробно разобран метод **разреженных автокодировщиков** [3]: архитектура SAE (1.4)–(1.5), функция потерь (1.7) с L1-регуляризацией, система оценки признаков через ручную и автоматизированную интерпретируемость, а также каузальная верификация через feature steering.
- Проанализировано **масштабирование метода** [4]: архитектура ReLU + L1 с взвешиванием штрафа по норме декодера, законы масштабирования (1.10), обнаружение признаков безопасности и мультимодальных концептов в Claude 3 Sonnet при размере словаря до 16М признаков.

Значимость подхода. Три рассмотренные работы показывают: *механистическая интерпретируемость масштабируемых языковых моделей достижима*. SAE позволяет преобразовать непрозрачные активации в словарь интерпретируемых признаков, сохраняя точность описания вычислений. Обнаружение признаков, связанных с безопасностью (prompt injection, манипуляция, нежелательный контент), непосредственно применимо для аудита и верификации безопасного поведения моделей.

Перспективы. Среди открытых задач - систематическая каузальная верификация признаков, разработка теоретических гарантий восстановления "истинных" признаков и снижение вычислительной стоимости методов для промышленного применения.

Библиографический список

1. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. — 2017. — Т. 30. — URL: <https://arxiv.org/abs/1706.03762>.
2. Toy Models of Superposition / N. Elhage [и др.] // Transformer Circuits Thread. — 2022. — URL: https://transformer-circuits.pub/2022/toy_model/index.html.
3. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning / T. Bricken [и др.] // Transformer Circuits Thread. — 2023. — URL: <https://transformer-circuits.pub/2023/monosemantic-features/index.html>.
4. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet / A. Templeton [и др.] // Transformer Circuits Thread. — 2024. — URL: <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>.
5. *Bereska L., Gavves E.* Mechanistic Interpretability for AI Safety — A Review // arXiv preprint arXiv:2404.14082. — 2024. — URL: <https://arxiv.org/abs/2404.14082>.
6. Efficient Estimation of Word Representations in Vector Space / T. Mikolov [и др.] // arXiv preprint arXiv:1301.3781. — 2013. — URL: <https://arxiv.org/abs/1301.3781>.
7. The Pile: An 800GB Dataset of Diverse Text for Language Modeling / L. Gao [и др.] // arXiv preprint arXiv:2101.00027. — 2020. — URL: <https://arxiv.org/abs/2101.00027>.
8. *Olshausen B. A., Field D. J.* Sparse Coding with an Overcomplete Basis Set: A Strategy Employed by V1? // Vision Research. — 1997. — Т. 37, № 23. — С. 3311—3325.

Терминологический словарь

Overfitting Переобучение модели.

Regularization Регуляризация.

В Исходные данные экспериментов

В.1 Протоколы

Текст протоколов.

С Листинги кода (фрагменты)

```
import numpy as np
def loss(y_true, y_pred):
    return np.mean((y_true - y_pred)**2)
```