

**Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский университет
«Высшая школа экономики»**

Факультет компьютерных наук

Магистерская программа Машинное обучение в цифровом продукте

КУРСОВАЯ РАБОТА

На тему (рус.) Интерпретируемость больших языковых моделей

На тему (англ.) Interpretability of Large Language Models

Студент

Пак Александр Данилович

(Ф.И.О., подпись)

Руководитель КР

Мунькина Виктория Сергеевна,
Старший инженер

(должность, звание, Ф.И.О, подпись)

Москва, 2026 г.

Аннотация

В данной курсовой работе рассматриваются методы механистической интерпретируемости больших языковых моделей (LLM). Основное внимание уделяется гипотезе суперпозиции, объясняющей полисемантичность нейронов, и методу разреженных автокодировщиков (SAE), который позволяет выделять более интерпретируемые признаки из внутренних активаций модели. Также анализируется масштабирование SAE на крупные языковые модели (LLM) и связь найденных признаков с задачами безопасности.

В экспериментальной части воспроизводятся основные этапы подхода "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet" на открытой модели Qwen3-1.7B. Для выбранного слоя модели собираются активации, обучается SAE с расширенным словарем признаков, оценивается качество восстановления, выполняется автоматическая разметка наиболее активных признаков и проводится проверка feature steering. Полученные результаты показывают, что SAE способен хорошо восстанавливать активации и выделять признаки, влияющие на генерацию модели, однако качество интерпретируемости ограничивается недостаточной разреженностью признаков. Работа демонстрирует возможности и ограничения применения методов механистической интерпретируемости к открытым языковым моделям меньшего масштаба.

Abstract

This course paper studies mechanistic interpretability methods for large language models. The main focus is on the superposition hypothesis, which explains neuronal polysemanticity, and on sparse autoencoders (SAEs), which make it possible to extract more interpretable features from internal model activations. The paper also reviews the scaling of SAEs to large language models and discusses how extracted features can be related to AI safety problems.

The experimental part reproduces the main stages of this SAE-based inter-

pretability pipeline on the open Qwen3-1.7B model. Activations are collected from a selected model layer, an SAE with an expanded feature dictionary is trained, reconstruction quality is evaluated, the most active features are automatically labeled, and a pilot feature steering experiment is performed. The results show that the SAE can reconstruct activations well and identify features that influence model generation; however, interpretability is limited by insufficient feature sparsity. The paper demonstrates both the possibilities and limitations of applying mechanistic interpretability methods to smaller open language models.

Оглавление

Аннотация	1
Abstract	1
Введение	5
1 Обзор методов интерпретируемости	8
1.1 Суперпозиция в нейронных сетях	8
1.1.1 Понятие признака	8
1.1.2 Полисемантичесность нейронов	9
1.1.3 Гипотеза суперпозиции	9
1.1.4 Моносемантичесность как цель интерпретируемости . .	11
1.1.5 Вывод по разделу	11
1.2 SAE для поиска моносемантических признаков	12
1.2.1 Постановка задачи	12
1.2.2 Признаки как декомпозиция активаций	13
1.2.3 Архитектура SAE	13
1.2.4 Функция потерь	15
1.2.5 Процедура обучения	15
1.2.6 Метрики оценки	16
1.2.7 Найденные признаки	17
1.2.8 Анализ признаков	17
1.2.9 Выводы	18
1.3 Масштабирование SAE на промышленные LLM	19
1.3.1 Постановка эксперимента	19
1.3.2 Примеры найденных признаков	19
1.3.3 Управление поведением LLM через feature steering . .	21
1.3.4 Gemma Score: масштабирование на семейство Gemma 2	23
1.3.5 Qwen-Score: SAE для семейства Qwen	23
1.3.6 Ограничения	24
1.3.7 Выводы	25

2 Экспериментальная часть	26
2.1 Цель и постановка эксперимента	26
2.2 Сбор активаций	26
2.3 Обучение SAE	27
2.4 Метрики	28
2.5 Автоматическая интерпретация признаков	29
2.6 Feature steering	30
2.7 Выводы по эксперименту	30
Заключение	32
Библиографический список	34
Приложение	36

Введение

Большие языковые модели, основанные на архитектуре трансформера [1], стали одним из ключевых направлений современного машинного обучения. Такие модели способны генерировать связный текст, решать прикладные задачи, писать код и обобщать информацию из больших массивов данных. Однако рост качества и масштаба моделей сопровождается ростом их непрозрачности: внутренние вычисления распределены между миллиардами параметров и активациями, поэтому поведение модели трудно объяснить через отдельные понятные человеку правила.

Эта проблема особенно важна для безопасности, если LLM используется в реальном продукте, недостаточно знать только ее итоговую точность на тестовых наборах. Необходимо понимать, какие внутренние признаки модель использует, как эти признаки связаны с генерацией ответа и можно ли заранее обнаруживать нежелательные механизмы поведения, например склонность к следованию вредным инструкциям, манипуляции или некорректному переключению языка. Этими вопросами занимается механистическая интерпретируемость - направление, цель которого состоит в восстановлении конкретных вычислительных механизмов нейронной сети.

В данной работе механистическая интерпретируемость рассматривается через линию исследований, связывающую три идеи. Первая идея - гипотеза суперпозиции, согласно которой нейронные сети могут хранить больше признаков, чем имеют нейронов, за счет размещения признаков в неортогональных направлениях пространства активаций [2]. Эта гипотеза объясняет, почему отдельные нейроны часто оказываются полисемантическими и не соответствуют одному устойчивому понятию. Вторая идея - использование разреженных автокодировщиков (Sparse Autoencoders, SAE) для декомпозиции активаций языковой модели на более интерпретируемые признаки [3]. Третья идея - масштабирование этого подхода на крупные языковые модели и проверка того, что извлеченные признаки могут не только описывать внутренние представления, но и влиять на поведение модели [4].

Работа не ограничивается теоретическим обзором. Во второй главе

проводится эксперимент, вдохновленный подходом "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet"[4]. Поскольку модель Claude 3 Sonnet и масштабные SAE от Anthropic недоступны для полного воспроизведения в рамках курсовой работы, эксперимент переносится в доступную исследовательскую постановку, где используется открытая модель Qwen3-1.7B, собираются активации ее среднего слоя, обучается SAE меньшего масштаба, выполняется автоматическая интерпретация наиболее активных признаков и проверяется возможность feature steering через вмешательство в выбранный признак.

Объектом исследования являются большие языковые модели (LLM) на основе архитектуры трансформера и внутренние представления, возникающие в процессе обработки текстовых данных.

Предметом исследования выступают методы механистической интерпретируемости больших языковых моделей (LLM), гипотеза суперпозиции, разреженные автокодировщики (SAE) для выделения признаков из активаций, автоматическая разметка признаков и управление поведением модели через feature steering.

Цель работы заключается в анализе современных методов механистической интерпретируемости больших языковых моделей (LLM) и в экспериментальной проверке воспроизводимости основных этапов подхода с SAE на открытой модели Qwen3-1.7B.

Для достижения поставленной цели необходимо решить следующие задачи:

1. рассмотреть гипотезу суперпозиции и объяснить ее связь с полисемантичностью нейронов
2. изучить метод разреженных автокодировщиков как способ извлечения интерпретируемых признаков из активаций языковых моделей
3. проанализировать результаты масштабирования SAE на крупные модели и связь найденных признаков с задачами безопасности
4. собрать активации открытой модели Qwen3-1.7B и обучить SAE на выбранном слое модели

5. оценить качество полученного SAE по метрикам реконструкции, разреженности и автоматической интерпретации признаков
6. проверить, может ли вмешательство в отдельный SAE-признак менять генерацию модели в задаче feature steering

Практическая значимость работы состоит в том, что она показывает применимость основных этапов подхода не только к закрытым промышленным моделям, но и к открытой модели меньшего масштаба. Полученные результаты также демонстрируют ограничения такого воспроизведения, хорошее восстановление активаций само по себе не гарантирует моносемантическую признаков, поэтому для интерпретируемости важны разреженность, качество автоматических меток и каузальная проверка признаков.

Работа состоит из двух глав. В первой главе рассматриваются теоретические основы механистической интерпретируемости, суперпозиция, полисемантическую нейронов, разреженные автокодировщики, масштабирование SAE и примеры связанных проектов Gemma Scope и Qwen-Scope. Во второй главе описан собственный эксперимент, сбор активаций Qwen3-1.7B, обучение SAE, анализ метрик, автоматическая интерпретация признаков и проверка feature steering. В заключении обобщаются результаты обзора и эксперимента, а также формулируются направления дальнейшей работы.

1 Обзор методов интерпретируемости

1.1 Суперпозиция в нейронных сетях

Данный раздел опирается на обзорную работу "Mechanistic Interpretability for AI Safety - A Review"[5] и основополагающую работу "Toy Models of Superposition"[2]. Вместе они формируют концептуальную базу всего направления механистической интерпретируемости, без которой невозможно понять ни метод разреженных автокодировщиков, ни масштабирование признаков на промышленные модели.

1.1.1 Понятие признака

По определению авторов [5], признак является фундаментальной единицей внутренних представлений нейронной сети, наименьшая независимо значимая единица, которую нельзя разложить на более простые независимые факторы.

Главная идея, объединяющая работы [2] и [5], — гипотеза линейного представления. Согласно ей, признаки, которые сеть научилась извлекать из данных, — это не отдельные нейроны, а векторы в пространстве активаций. Иными словами, признак кодируется не одним нейроном, а линейной комбинацией многих нейронов одновременно. Каждому признаку i сопоставляется единичный вектор $\mathbf{f}_i \in \mathbb{R}^n$ в пространстве активаций $\mathbb{R}^n$, а "присутствие" признака в данном входе $\mathbf{x}$ выражается скалярным произведением $\langle \mathbf{x}, \mathbf{f}_i \rangle$.

Косвенным свидетельством в пользу этой гипотезы служит векторная арифметика в пространствах эмбедингов для word2vec [6], например, king — man + woman $\approx$ queen.

Важно различать нейрон и признак. Нейрон — конкретная вычислительная единица сети, одна координата в пространстве активаций. Признак — абстрактная единица, соответствующая некоторому вектору в этом же пространстве. В идеальном случае каждый нейрон соответствует ровно одному признаку. На практике это утверждение нарушается.

1.1.2 Полисемантичность нейронов

Полисемантичность - свойство нейрона активироваться на несколько семантически несвязанных признаков [5]. Полисемантический нейрон реагирует на разные, внешне не связанные входные данные, например, один и тот же нейрон может активироваться на упоминания столиц, на арабские символы и на фрагменты кода, признаки с совершенно разными смыслами.

Полисемантичность особенно выражена в трансформерных моделях и является главной проблемой в механистической интерпретируемости, зная активацию нейрона, невозможно однозначно установить, какой именно признак закодирован в данном конкретном контексте.

Причины полисемантичности. В статье [5] выделяют три конкурирующие гипотезы:

1. Несовпадение признаков с базисом нейронов, т.е. в архитектурах без структурно привилегированного базиса нет оснований ожидать совпадения признаков с осями нейронов. Полисемантичность в таком случае неизбежна независимо от числа признаков.
2. Методы регуляризации, например, dropout, распределяют представление одного признака по нескольким нейронам, добавляя полисемантичности.
3. Суперпозиция(основная гипотеза) - число признаков в данных существенно превышает число нейронов сети. В такой ситуации модель вынуждена сжимать несколько признаков в один и тот же набор нейронов.

1.1.3 Гипотеза суперпозиции

Гипотеза суперпозиции [2] утверждает: нейронные сети представляют больше признаков, чем имеют нейронов, кодируя эти признаки в виде комбинаций нейронных активаций.

Игрушечная модель. В статье [2] авторы исследуют минималистичную модель, в которой d разреженных входных признаков сжимаются в $n < d$ нейронов и восстанавливаются обратно:

$$\mathbf{h} = \mathbf{W}\mathbf{x}, \quad \mathbf{x}' = \text{ReLU}(\mathbf{W}^\top \mathbf{h} + \mathbf{b}), \quad (1.1)$$

где $\mathbf{W} \in \mathbb{R}^{n \times d}$ - матрица проекции, $\mathbf{x} \in \mathbb{R}^d$ - входной вектор (d признаков), $\mathbf{h} \in \mathbb{R}^n$ - сжатое скрытое представление (n нейронов).

Функция потерь взвешивает ошибки восстановления по важности признаков:

$$\mathcal{L} = \sum_{\mathbf{x}} \sum_{i=1}^d a_i (x_i - x'_i)^2, \quad (1.2)$$

где $a_i > 0$ — важность i -го признака.

Основные результаты игрушечной модели. Эксперименты с этой моделью демонстрируют качественный переход:

- **Без суперпозиции:** сеть хранит ограниченное число признаков, представляя каждый строго вдоль одного нейрона; остальные признаки игнорируются.
- **С суперпозицией:** сеть "упаковывает" значительно больше признаков, чем нейронов, размещая их в почти ортогональных суперпозициях за счет малой вероятности одновременной активации.

Привилегированный и непривилегированный базисы. Важным концептом является тип базиса представления [5]:

- **Привилегированный базис** формируется элементами, выделяющими конкретные направления, например, нелинейными активациями ReLU. В таком базисе признаки могут совпасть с направлениями нейронов, что способствует моносемантичности.
- **Непривилегированный базис** - пространство, в котором модель не выделяет никаких конкретных направлений. Признаки не обязаны

совпадать с осями нейронов, поэтому полисемантичность является неизбежной.




Рис. 1. Визуализация привилегированного и непривилегированного базисов, моносемантических и полисемантических нейронов

1.1.4 Моносемантичность как цель интерпретируемости

Моносемантичность - свойство нейрона соответствовать только одному семантическому признаку [5]. Моносемантический нейрон однозначно интерпретируем: его активация свидетельствует о наличии конкретного признака.

В полностью моносемантической нейронной сети задача механистической интерпретируемости сводилась бы к описанию каждого нейрона.

Полисемантический нейрон можно представить как сжатую проекцию нескольких нейронов гипотетической более широкой сети, в которой каждый нейрон соответствовал бы ровно одному признаку. На самом деле обученная сеть, ограниченная в числе нейронов, проецирует это моносемантическое пространство в меньшую размерность, порождая полисемантичность. Задача методов интерпретируемости - обратить эту проекцию и восстановить исходное пространство признаков. Именно эту цель преследует метод разреженных автокодировщиков (SAE), рассматриваемый в следующем разделе.

1.1.5 Вывод по разделу

Понятие признака как вектора активаций и явление суперпозиции образуют фундамент для механистической интерпретируемости. Полисеман-

тичность нейронов является ожидаемым следствием обучения: число признаков сильно превышает число нейронов, и сеть вынуждена сжимать.

Моносеманτικότητα, напротив, представляет собой идеальное состояние - ситуацию «один нейрон, один признак», при которой интерпретация нейронной сети становится решаемой. Необходимы методы, способные "распутать" суперпозицию и извлечь однозначные признаки из наблюдаемых активаций. Эту задачу решают разреженные автокодировщики (SAE), которым посвящен следующий раздел.

1.2 SAE для поиска моносемантических признаков

В работе "Towards Monosemanticity: Decomposing Language Models With Dictionary Learning"[3] авторы предложили метод, направленный на решение проблемы полисемантической нейронов языковых моделей с помощью SAE (разреженных автокодировщиков).

1.2.1 Постановка задачи

Рассматривается однослойный трансформер с размером модели 512, обученный на корпусе The Pile [7]. Объектом анализа является выход MLP слоя, вектор $\mathbf{x} \in \mathbb{R}^n$, где $n = 512$.

Целью является разложить выход MLP слоя на признаки, количество которых больше числа нейронов. Задача состоит в том, чтобы получить словарь признаков, в идеальном случае полученный словарь будет содержать моносемантические нейроны, соответствующие признакам. Для поиска такого разреженного представления применяется SAE (разреженный автокодировщик).




Рис. 2. Применение SAE к выходу MLP-слоя однослойного трансформера.

1.2.2 Признаки как декомпозиция активаций

Прежде чем перейти к архитектуре SAE, авторы формулируют критерий хорошей декомпозиции. Декомпозиция активаций является качественной, если:

1. восстановленные активации $\hat{\mathbf{x}}$ близки к исходным $\mathbf{x}$
2. среднее число ненулевых признаков на токен мало
3. каждый найденный признак активируется на семантически схожем множестве токенов и поддается человеческому пониманию
4. признаки, найденные при разных запусках обучения, похожи друг на друга

1.2.3 Архитектура SAE

SAE состоит из энкодера и декодера с общим скрытым пространством размерности m .

Энкодер принимает вектор активаций $\mathbf{x} \in \mathbb{R}^n$, вычитает смещение декодера и применяет преобразование с функцией активации ReLU:

$$\mathbf{f}(\mathbf{x}) = \text{ReLU}(\mathbf{W}_{\text{enc}}(\mathbf{x} - \mathbf{b}_{\text{dec}}) + \mathbf{b}_{\text{enc}}), \quad (1.3)$$

где $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{m \times n}$ - матрица весов энкодера, $\mathbf{b}_{\text{enc}} \in \mathbb{R}^m$ - смещение энкодера, $\mathbf{b}_{\text{dec}} \in \mathbb{R}^n$ - смещение декодера (вычитается до кодирования), а $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^m$ - вектор активаций признаков.

Декодер восстанавливает исходный вектор из активаций признаков:

$$\hat{\mathbf{x}} = \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) + \mathbf{b}_{\text{dec}}, \quad (1.4)$$

где $\mathbf{W}_{\text{dec}} \in \mathbb{R}^{n \times m}$.




Рис. 3. Архитектура разреженного автокодировщика (SAE).

Также применяется два приема, которые сильно влияют на качество разложения и интерпретируемость признаков

- Перед подачей активационного вектора в энкодер из него вычитается смещение $\mathbf{b}_{\text{dec}}$, которое равно среднему значению MLP активаций. Такое преобразование позволяет убрать постоянную составляющую и в энкодере использовать только на отклонения от среднего, т.к. они несут информацию
- ReLU обнуляет отрицательные активации, обеспечивая неотрицательность $\mathbf{f}(\mathbf{x})$ и вводя разреженность, следовательно в реконструкции участвуют только часть признаков.

1.2.4 Функция потерь

SAE обучается минимизировать функцию потерь:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{ошибка реконструкции}} + \lambda \underbrace{\|\mathbf{f}(\mathbf{x})\|_1}_{\text{штраф за плотность}}, \quad (1.5)$$

где $\lambda > 0$ - коэффициент регуляризации, отвечающий за баланс между качеством реконструкции и разреженностью активаций признаков.

Ошибка реконструкции (L_2) заставляет SAE восстанавливать исходные активации, но если бы SAE обучалось только на такую функцию потерь, то модель не смогла бы получать разреженные представления.

L_1 -штраф штрафует за сумму абсолютных значений активаций признаков, что и заставляет вектор активаций признаков быть разреженным.

Роль гиперпараметра λ :

- При малом λ SAE точно восстанавливает $\mathbf{x}$, но признаки плотные и плохо интерпретируемые
- При большом λ , признаки разреженные, но реконструкция неточная, теряется часть информации исходных активаций

1.2.5 Процедура обучения

SAE обучается на активациях, собранных заранее при прогоне однослойного трансформера на случайных токенах из корпуса The Pile [7] - открытого датасета объемом > 800 ГБ, включающий в себя разнообразные тексты на разных языках. Обучение SAE ведется уже на активациях уже обученной LLM.

Авторы обучают SAE с различными коэффициентами расширения m/n : $1\times$, $2\times$, $4\times$, $8\times$, $16\times$, $32\times$ относительно $n = 512$. Это дает словари от 512 до 16384 признаков. Основные результаты получены на словаре $m = 4096$ ($8\times$).

В процессе обучения часть признаков может так и не начать активироваться, т.е. появятся "мертвые" признаки. Это происходит из-за того, что

градиент через неактивные нейроны ReLU равен нулю. Авторы используют эвристику периодической переинициализации "мертвых" признаков, которая помогает задействовать неиспользуемые признаки.

1.2.6 Метрики оценки

Для оценки качества обученного SAE обычно используют следующие методы.

Оценка качества реконструкции

- **L_2 -ошибка** - среднеквадратическое отклонение восстановленных активаций от исходных
- **Доля объясненных потерь** (fraction of loss recovered): насколько использование $\hat{\mathbf{x}}$ вместо $\mathbf{x}$ изменяет cross-entropy loss LLM. Если подставить реконструкции SAE обратно в модель вместо исходных активаций MLP, деградация потерь показывает, сколько информации утеряно при кодировании.

Оценка разреженности

- **L_0 -норма** - среднее число ненулевых активаций $f_i(\mathbf{x})$ на токен. Т.е. чем меньше, тем более разреженным является представление.
- **L_1 -норма**: ограничивает сумму абсолютных значений активаций признаков

Оценка интерпретируемости

Для автоматизации применяют LLM-as-a-Judge [8]:

1. Для признака i отбираются k токенов с наибольшей активацией
2. Языковая модель генерирует лэйбл, описание признака
3. На отдельной выборке из k' токенов LLM просят предсказать, будет ли признак активен для каждого токена;

4. Вычисляются доля правильно определенных активаций

1.2.7 Найденные признаки

Словарь из 4096 признаков ($8\times$ увеличение) содержит разнообразные интерпретируемые концепты: числовые (*base-10 digits, decimal fractions*), биологические (*DNA sequences, periodic table elements*), лингвистические (*Hebrew, Cyrillic, Arabic script*), связанные с кодом (*function arguments, Python imports*) и академические (*citations, Bible quotations*).

Ключевой результат: признаки SAE значительно более моносемантичны, чем исходные нейроны - наиболее активирующие токены каждого признака принадлежат одной семантической категории, следовательно такие признаки можно описать каким-то лэйблом.

1.2.8 Анализ признаков

Помимо анализа отдельных признаков, авторы исследуют свойства полученного словаря.

Дробление признаков

При увеличении размера словаря от $1\times$ до $32\times$ наблюдается дробление признаков: признак, представлявший в малом словаре широкую концепцию, в большем словаре разбивается на несколько более специфических подпризнаков. Например:

- Словарь 512: один признак «числа»;
- Словарь 4096: признаки «арабские числа», «числа в скобках», «числа в десятичных дробях», «числа в временных обозначениях» и т.д.

Дробление свидетельствует о том, что SAE выявляет иерархическую структуру признакового пространства и что большие словари действительно "открывают" новые, более тонкие различия.

Универсальность признаков

Сравнение признаков, выученных в разных запусках SAE (с различными инициализациями и разными коэффициентами расширения), показывает высокую степень воспроизводимости. Признаки, найденные в одном словаре, имеют хорошо выраженный "двойник" в другом словаре.

"Мертвые" признаки

Часть признаков остается «мертвой», т.е. никогда не активируются. При $8\times$ увеличении доля "мертвых" признаков составляет порядка 20-30%. Авторы интерпретируют это как ограничение текущего метода обучения, а не как свидетельство того, что в активациях нет дополнительных структур.

1.2.9 Выводы

Работа "Towards Monosemanticity: Decomposing Language Models With Dictionary Learning" вносит существенный вклад в механистическую интерпретируемость, демонстрируя:

1. Разреженные автокодировщики позволяют декомпонировать полисемантические нейронные активации в более интерпретируемое пространство моносемантических признаков
2. Функция потерь (1.5) обеспечивает баланс между точностью реконструкции и разреженностью при контролируемом λ
3. Увеличение размера словаря приводит к дроблению признаков и росту интерпретируемости
4. Автоматическая оценка интерпретируемости с помощью LLM позволяет масштабировать анализ на тысячи признаков.

1.3 Масштабирование SAE на промышленные LLM

Проверив гипотезы на игрушечной модели, модели с одним трансформерным блоком, можно переходить на промышленные LLM, в данном разделе больше внимание будет уделено работе "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet"[4], но также затроним работы связанные с другими моделями, такими как Qwen и Gemma.

1.3.1 Постановка эксперимента

В исследовании [4] эксперименты проводились на Claude 3 Sonnet, LLM с многомиллиардным числом параметров. SAE применяется к выходу трансформерного блока из середины сети.

Авторы [4] используют ту же базовую архитектуру SAE с ReLU и L1, что и в [3]. Обучали SAE трех размеров: 1 048 576 ($\approx 1M$), 4 194 304 ($\approx 4M$) и 33 554 432 ($\approx 34M$) признаков. SAE обучался на активациях, собранных на внутреннем датасете Anthropic. Для визуализации найденных признаков использовались два открытых датасета: The Pile (без подмножества books3) [7] и Common Crawl [9]. Полученные после всех трех SAE реконструкции объясняли не менее 65% дисперсии активаций моделей, а доля мертвых признаков варьировалось от 2% до 65% в зависимости от размера словаря признаков.

1.3.2 Примеры найденных признаков

"Golden Gate Bridge"

Один из наиболее известных примеров статьи - признак, соответствующий признаку относящемуся к "Golden Gate Bridge". Признак активируется одновременно на:

- текстовые упоминания моста в любом контексте
- изображения моста

- смежные признаки - Сан-Франциско, мосты и т.д.

Для проверки авторы применили **feature steering**, усиление признака в ≈ 10 раз, что приводило к тому, что модель начинала ассоциировать себя как мост в ответ на любой запрос. При отключении признака эффект полностью исчезал. Подробное описание метода — в подразделе 1.3.3.




Рис. 4. Пример признака "Golden Gate Bridge" с увеличенной активацией.

Признаки, связанные с безопасностью

Авторы [4] обнаружили ряд признаков, потенциально связанных с безопасностью модели. Но важное замечание, существование такого признака не означает, что модель ведет себя опасно, необходимо отличать знание о вредоносном поведении и его воспроизведение. Следовательно наличие и активность этих признаков позволяет контролировать такое поведение.

Выявлено три признака, связанных с уязвимостями:

- признак «unsafe code», активирующийся на уязвимости в системе безопасности и не только
- признак «code error», реагирующий на баги и исключения
- признак «backdoor»

Например, принудительная активация признака небезопасного кода приводит к тому, что модель генерирует код с утечками памяти, тогда как при нормальной работе она этого не делает.

Также были обнаружены признаки, активирующиеся на расистские, сексистские и другие поведения. Один из примеров, признак гендерного неравенства в профессиях, пример текстов на которых активируется такой

признак - соотношение мужчин и женщин среди медсестер или профессоров. Также были найдены признаки, связанные с ненавистью и оскорблениями, принудительная активация с увеличением в 20 раз заставляет модель генерировать расистские высказывания.

Выявлена группа признаков, связанных с разными формами «угодливости», такие как признак эмпатии и солидарности «yeah, me too», признак лести и признак саркастических похвал. Принудительная активация признака лести с увеличением в 5 раз заставляет модель хвалить пользователя по любому поводу.

Обнаружение подобных признаков в промышленных LLM важно для исследований безопасности, они позволяют проверять, при каких условиях эти признаки активируются, и изучать их вклад в поведение модели и возможности исключения соответствующего поведения.

1.3.3 Управление поведением LLM через feature steering

Работа [4] идет дальше простой детекции признаков и показывает, что при помощи SAE можно менять поведение модели.

Feature steering - метод целенаправленного изменения поведения языковой модели путем вмешательства в активации отдельных признаков SAE во время инференса. Вместо того чтобы воздействовать на веса модели или промпт, можно усиливать или подавлять конкретный признак, меняя поведение модели, добиваясь желаемого поведения. Есть много вариаций feature steering, но в статье [4] используется метод Activation Clamping:

Activation Clamping. Активация признака j принудительно фиксируется на заданном уровне c независимо от входа:

$$f_j(\mathbf{x}) \leftarrow c. \quad (1.6)$$




Рис. 5. Схема метода feature steering: принудительная фиксация активации признака SAE изменяет поведение модели.

Так, например, признак "Golden Gate Bridge" усиливался в ≈ 10 раз относительно средней активации (подраздел 1.3.2). Модель начинала описывать себя как мост в ответ на любой запрос. Эффект полностью пропал при отключении признака - это подтверждает работу метода Activation Clamping.

Ограничения метода. При умеренных s Feature steering стабилен и поведение изменяется предсказуемо. При слишком больших s есть вероят-

ность достаточно сильно испортить модель и получить непредсказуемое поведение.

1.3.4 Gemma Score: масштабирование на семейство Gemma 2

В работе "Gemma Score"[10] метод SAE применяется к семейству моделей Gemma 2 (2B, 9B, 27B), при этом обучаются SAE для каждого слоя каждой модели. Обучались SAE с размерами словаря от 16 384 до 1 048 576 признаков.

Вместо функции активации с ReLU и L1-штрафом авторы предлагают JumpReLU - функцию активации с обучаемым порогом θ :

$$f_i(\mathbf{x}) = \text{ReLU}(z_i - \theta_i) \cdot \mathbf{1}[z_i > \theta_i], \quad z_i = (\mathbf{W}_{\text{enc}} \mathbf{x} + \mathbf{b}_{\text{enc}})_i, \quad (1.7)$$

где порог θ_i обучается отдельно для каждого признака. При использовании L1-штрафа активации признаков оказываются искусственно заниженными, штраф за ненулевые значения вынуждает модель уменьшать их даже тогда, когда признак действительно активен. JumpReLU делает так, что признак либо полностью зануляется, если активация ниже порога θ_i , либо активируется без какого-либо занижения.

1.3.5 Qwen-Score: SAE для семейства Qwen

В работа "Qwen-Score"[11] авторы применяют SAE к моделям Qwen. Вместо L1-штрафа используют Топ-К активации, на каждый токен остаются активными ровно k признаков с наибольшими преактивациями, остальные обнуляются. Значение k фиксировано во время обучения ($k = 50$ или $k = 100$). Это гарантирует постоянный уровень разреженности без подбора гиперпараметра λ . Ширина словаря признаков составляла $16\times$ от размерности модели. Ключевой практический результат работы - метод SASFT (Sparse Autoencoder-guided Supervised Fine-Tuning), использование признаков SAE в процессе дообучения модели.



Рис. 6. Пример code-switching

Стандартный SFT обучает модель выдавать желаемые результаты, не вмешиваясь во внутренние представления о мире. SASFT дополняет его вспомогательной функцией потерь, которая штрафует активацию конкретных признаков SAE, связанных с нежелательным поведением.

Проблема code-switching - нежелательное переключение языка внутри ответа, например, модель отвечает на китайском, когда вопрос задан на английском. Авторы предлагают на корпусе проблемных примеров с переключением языка отбирать признаки SAE с наибольшей активацией, найти среди них специфичные для языка признаки. Затем при дообучении к стандартной функции потерь добавить слагаемое, минимизирующее активации найденных признаков на нежелательных примерах. Таким образом модель учится одновременно давать правильные ответы и подавлять активность проблемных признаков.

Такой подход снизил частоту code-switching на 50% [11]. При этом такого рода вмешательства затрагивают только целевые признаки. SASFT демонстрирует, что SAE - не только инструмент анализа, но и инструмент для улучшения поведения модели или же получения определенного поведения.

1.3.6 Ограничения

При недостаточном размере словаря SAE может сжимать два коррелирующих признака в один, признак A оказывается закодирован не отдельно, а только в связке $A + B$. Это нарушает моносемантичность и затрудняет интерпретацию.

Масштабирование словаря признаков привести к значительным уве-

личениями требований к памяти. Например, матрица энкодера SAE с 16М признаков при размерности модели $d = 4096$ имеет размер $W_{\text{enc}} \in \mathbb{R}^{16,000,000 \times 4096}$, что в формате float16 занимает ≈ 250 ГБ - больше, чем весит сама языковая модель. Это делает инференс с SAE затруднителен без специальных методов и квантизации.

1.3.7 Выводы

В рассмотренных статьях можно выделить несколько ключевых направлений.

Во-первых, feature steering, [4] исследователи из Anthropic обнаружили признаки, связанные с опасным поведением модели: бэкдоры в коде, сексизм и т.д. . Так принудительная активация признака бэкдора заставляет модель писать вредоносный код, активация признака угодливости - хвалить пользователя за любую глупость. Это значит, что мониторинг активаций таких признаков во время инференса - потенциально рабочий способ раннего обнаружения опасного поведения.

Во-вторых, обе последующие работы предложили альтернативные функции активации. Gemma Scope [10] ввёл JumpReLU (1.7) с обучаемым порогом, Qwen-Score [11] - Top-K с фиксированным числом активных признаков. Оба подхода решают одну проблему, L1-штраф занижает амплитуду активных признаков, искажая их интерпретацию.

В-третьих, Qwen-Score предложил SASFT - метод, в котором сигналы SAE встраиваются непосредственно в процесс дообучения. Вместо того чтобы только наблюдать за признаками, авторы используют их для дополнения к функции потерь. На практике это позволило снизить частоту нежелательного переключения языка на 50%, не меняя остального поведения модели.

2 Экспериментальная часть

2.1 Цель и постановка эксперимента

Экспериментальная часть работы вдохновлена подходом Anthropic [4]: обучить SAE на внутренних активациях языковой модели, найти интерпретируемые признаки и проверить, можно ли управлять поведением модели через вмешательство в эти признаки. Полное воспроизведение экспериментов Anthropic невозможно из-за закрытости Claude 3 Sonnet и высокой вычислительной стоимости реализации словарей на миллионы признаков. Поэтому задачей будет являться воспроизвести данный эксперимент на открытой модели, в качестве таковой взята Qwen3-1.7B.

Эксперимент включает четыре этапа:

1. сбор активаций модели Qwen3-1.7B на датасете
2. обучение SAE на выбранном слое модели
3. оценка качества SAE
4. проверка feature steering для выбранных признаков

Для построения SAE возьмем выход 14-го слоя, в Qwen3-1.7B 28 слоев. Такой выбор близок к постановке задачи из статьи [4], где SAE обучается на среднем слое

2.2 Сбор активаций

Для сбора активаций использовалась модель Qwen/Qwen3-1.7B. Тексты брались из датасета OpenWebText [12]. Модель прогонялась на датасете с сохранением выходов нужного слоя; для этого использовалась библиотека TransformerLens [13]. Полученный набор активаций использовался для дальнейшего обучения SAE и интерпретации признаков.

Таблица 2.1. Параметры сбора активаций

Параметр	Значение
Модель	Qwen/Qwen3-1.7B
Анализируемый слой	14
Размерность активаций	$d_{\text{in}} = 2048$
Датасет	OpenWebText
Число текстов	100000
Максимальная длина контекста	512 токенов
Число сохраненных токенов	45 257 971

В результате был получен датасет активаций размерности 245 257 971. Вместе с активациями сохранялись идентификаторы токенов, позиция токена в исходном тексте и индекс текста. Эта информация позже использовалась для получения контекстов, на которых признаки SAE активируются сильнее всего.

2.3 Обучение SAE

Для обучения использовался стандартный SAE из библиотеки SAE-Lens: энкодер и декодер с ReLU-активацией и L1-регуляризацией признаков. Размер словаря был выбран равным 32768 признакам, что соответствует расширению $16\times$ относительно размерности входного пространства:

$$\frac{d_{\text{SAE}}}{d_{\text{in}}} = \frac{32768}{2048} = 16. \quad (2.1)$$

Функция потерь совпадает с базовой постановкой SAE:

$$\mathcal{L} = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 + \lambda \|\mathbf{f}(\mathbf{x})\|_1, \quad (2.2)$$

где $\lambda = 10^{-3}$. Обучение выполнялось $\approx 20\,000$ шагов с batch size 2048 и learning rate $5 \cdot 10^{-5}$. Для валидации использовались 5% собранных активаций.

Таблица 2.2. Параметры обучения SAE

Параметр	Значение
Архитектура	StandardSAE
d_{in}	2048
d_{SAE}	32768
Коэффициент расширения	$16\times$
Batch size	2048
Число шагов	$\approx 20\,000$
Learning rate	$5 \cdot 10^{-5}$
L1 coefficient	10^{-3}
Доля валидации	0.05
Seed	7

2.4 Метрики

Качество SAE оценивалось относительно простого baseline, который предсказывает активации на средние активацию по обучающей выборки. В ходе обучения использовалась метрика activation reconstruction score:

$$s_{\text{rec}} = 1 - \frac{\text{MSE}_{\text{SAE}}}{\text{MSE}_{\text{baseline}}}. \quad (2.3)$$

Если s_{rec} близок к 1, SAE восстанавливает активации существенно лучше среднего вектора.

Таблица 2.3. Итоговые метрики обучения SAE

Метрика	Train	Test
MSE	50.60	30.73
L1 loss	11.44	11.28
L_0 , активных признаков на токен	18663.33	18682.26
Activation reconstruction score	0.884	0.929
Доля мертвых признаков	0.0	0.0

Главное проблемой полученного SAE является слабая разреженность, т.к. среднее число активных признаков на токен равно примерно 18.7 тыс. из 32.8 тыс., это возникает из-за того, что остается много околонулевых активаций. С точки зрения reconstruction score SAE работает хорошо, но с точки зрения моносемантическойности признаки можно анализировать, однако их нельзя считать полностью разделенными.

2.5 Автоматическая интерпретация признаков

Для интерпретации были выбраны 5000 признаков с наибольшей максимальной активацией. Для каждого признака извлекались 15 фрагментов текста, в которых данный признак активировался сильнее всего. Затем LLM-as-a-Judge Qwen/Qwen3.5-9B получал эти контексты и генерировал короткую метку, объяснение и confidence. Дополнительно проводилась проверка: по метке и новому контексту LLM должна была предсказать, активен ли соответствующий признак.

Таблица 2.4. Метрики автоматической интерпретации признаков

Метрика	Значение
Число размеченных признаков	5000
Число контекстов для judge-оценки	25000
Accuracy	0.566
Precision	0.872
Recall	0.156
F1	0.264
Средний confidence меток	0.947
Медианный confidence меток	0.950

Высокий precision при низком recall показывает, что полученные метки чаще оказываются полезными для уверенной идентификации сильных активаций, но плохо покрывают все случаи активации признака. Это согласуется с проблемой слабой разреженности, один признак может быть активен в большом числе контекстов, а LLM описание отражает только наиболее заметный кластер среди примеров с максимальной активацией.

Таблица 2.5. Примеры автоматически размеченных признаков

Feature id	Метка	Max activation
11850	headlines	172.41
25210	CTV News Staff	160.85
8057	modal verb	123.03
26928	Paris	169.67
451	male person	168.32

2.6 Feature steering

Последний этап эксперимента проверял, можно ли изменить генерацию модели через вмешательство в SAE признаки. Использовалась процедура activation clamping из [4], выбранные признаки фиксировались на заданном уровне, после чего проводился инференс с помощью зафиксированных активаций.

Для feature steering были выбран признак 26928. На одном и том же prompt "The capital of Germany is "сравнивались обычная генерация и генерации при clamping со значениями 50 и 100. В базовом режиме модель продолжала Berlin. После включения feature steering генерация заметно менялась уже при том же prompt и тех же параметрах сэмплирования: при $c = 50$ модель не начинала отвечать, что это Paris, а при $c = 100$ - ответила это Paris, что указывает на успешное вмешательство в модель.

Таблица 2.6. Результат feature steering

Режим	Результат
Baseline	The capital of Germany is Berlin.
$c = 50$	The capital of Germany is Berlin.
$c = 100$	The capital of Germany is Paris.

Результат steering можно считать успешным, изменение активаций SAE признаков не разрушило генерацию, а поменяло поведение модели на желаемое. Это качественно воспроизводит центральную идею [4], что признаки SAE можно использовать не только для интерпретации постфактум, но и как инструмент управления поведением модели.

2.7 Выводы по эксперименту

Эксперимент подтвердил воспроизводимость основных этапов подхода "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet"[4] на открытой модели:

1. активации Qwen3-1.7B можно собрать через TransformerLens hook и сохранить вместе с токеной метаданной

2. SAE с расширением $16\times$ успешно обучается выходах слоя и хорошо восстанавливает исходное представление
3. контексты с максимальной активацией признаков позволяют автоматически получать осмысленные лейблы для признаков
4. feature steering через SAE способен менять генерацию модели

Заключение

В данной курсовой работе были рассмотрены современные подходы к механистической интерпретируемости больших языковых моделей (LLM). В теоретической части была изучена гипотеза суперпозиции [2], объясняющая полисемантическую нейроны, а также метод разреженных автокодировщиков [3], который позволяет переходить от анализа отдельных нейронов к анализу более интерпретируемых признаков. Также было рассмотрено масштабирование SAE на крупные языковые модели [4] и показано, что такие признаки могут быть связаны не только с абстрактными признаками, но и с вопросами безопасности.

В экспериментальной части основные этапы подхода "Scaling Monosemanticity Extracting Interpretable Features from Claude 3 Sonnet" были воспроизведены на открытой модели Qwen3-1.7B. Были собраны активации среднего слоя модели, обучен SAE с размером словаря 32768 признаков и выполнена автоматическая разметка наиболее активных признаков. Полученный SAE показал хорошее качество восстановления активаций: activation reconstruction score составил 0.884 на train и 0.929 на test.

При этом эксперимент выявил важное ограничение: хорошая реконструкция не гарантирует хорошую интерпретируемость. Среднее число активных признаков на токен оказалось высоким, примерно 18.7 тыс. из 32.8 тыс., что указывает на недостаточную разреженность SAE. Автоматическая разметка признаков показала высокий precision и низкий recall: метки полезны для описания части сильных активаций, но не покрывают все случаи срабатывания признака.

Дополнительно была проведена проверка feature steering. Вмешательство в модель в признак связанный с Paris, изменило продолжение prompt: при достаточно сильном изменении модель начала отвечать Paris вместо Berlin. Это показывает, что признаки SAE могут использоваться не только для описания внутренних представлений, но и для воздействия на генерацию модели.

Таким образом, цель работы была достигнута: методы механистической интерпретируемости были проанализированы, а основные этапы под-

хода с SAE были воспроизведены на открытой модели Qwen3-1.7B. Дальнейшая работа может быть связана с подбором более сильной разреживающей регуляризации, сравнением L1, Top-K и JumpReLU SAE, и исследованием дообучения LLM с использованием полученных от SAE признаками.

Библиографический список

1. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. — 2017. — Т. 30. — URL: <https://arxiv.org/abs/1706.03762>.
2. Toy Models of Superposition / N. Elhage [и др.] // Transformer Circuits Thread. — 2022. — URL: https://transformer-circuits.pub/2022/toy_model/index.html.
3. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning / T. Bricken [и др.] // Transformer Circuits Thread. — 2023. — URL: <https://transformer-circuits.pub/2023/monosemantic-features/index.html>.
4. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet / A. Templeton [и др.] // Transformer Circuits Thread. — 2024. — URL: <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>.
5. *Bereska L., Gavves E.* Mechanistic Interpretability for AI Safety — A Review // arXiv preprint arXiv:2404.14082. — 2024. — URL: <https://arxiv.org/abs/2404.14082>.
6. Efficient Estimation of Word Representations in Vector Space / T. Mikolov [и др.] // arXiv preprint arXiv:1301.3781. — 2013. — URL: <https://arxiv.org/abs/1301.3781>.
7. The Pile: An 800GB Dataset of Diverse Text for Language Modeling / L. Gao [и др.] // arXiv preprint arXiv:2101.00027. — 2020. — URL: <https://arxiv.org/abs/2101.00027>.
8. A Survey on LLM-as-a-Judge / J. Gu [и др.] // arXiv preprint arXiv:2411.15594. — 2024. — URL: <https://arxiv.org/abs/2411.15594>.
9. *Common Crawl Foundation.* Common Crawl. — 2024. — URL: <https://commoncrawl.org>.

10. Gemma Scope: Open Sparse Autoencoders Everywhere All At Once on Gemma 2 / T. Lieberum [и др.] // arXiv preprint arXiv:2408.05147. — 2024. — URL: <https://arxiv.org/abs/2408.05147>.
11. *Qwen Team*. Qwen-Scope: Turning Sparse Features into Development Tools for Large Language Models // arXiv preprint arXiv:2605.11887. — 2026. — URL: <https://arxiv.org/abs/2605.11887>.
12. *Gokaslan A., Cohen V.* OpenWebText Corpus. — 2019. — URL: <https://skylion007.github.io/OpenWebTextCorpus/>.
13. *TransformerLensOrg*. TransformerLens: A Library for Mechanistic Interpretability of Generative Language Models. — 2026. — URL: <https://github.com/TransformerLensOrg/TransformerLens>.

Приложение

Исходный код проекта, использованный в экспериментальной части курсовой работы, размещен в репозитории GitHub:

<https://github.com/adpakw/llm-xai/tree/main>