

Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук
Магистерская программа «Машинное обучение в цифровом продукте»

КУРСОВАЯ РАБОТА

На тему (рус.): Интерпретируемость больших языковых моделей

На тему (англ.): Interpretability of Large Language Models

Студент: _____

(Ф.И.О., подпись)

Руководитель КР: _____

(должность, звание, Ф.И.О.,
подпись)

Москва, 2026

Аннотация

В данной курсовой работе представлен подробный обзор методов механистической интерпретируемости нейронных сетей, основанный на четырёх ключевых публикациях. Рассматриваются: математический фреймворк трансформерных цепей, включая QK/OV-декомпозицию остаточного потока и механизм индукционных голов — концепция «цепей» для разбора алгоритмов трансформера; теория суперпозиции, объясняющая полисемантическую нейроны через оптимальное хранение разреженных признаков; метод разреженных автокодировщиков (SAE) для извлечения моносемантических признаков из активаций MLP-слоя; а также масштабирование SAE на промышленную языковую модель Claude 3 Sonnet с получением миллионов интерпретируемых признаков. Для каждого метода приводятся основная идея, ключевые формулы, алгоритм и результаты применения. Работа предназначена для исследователей в области безопасности и интерпретируемости больших языковых моделей.

Abstract

This paper provides a detailed survey of mechanistic interpretability methods for neural networks, drawing on four foundational publications. We review: the mathematical framework for transformer circuits, introducing the residual-stream perspective, QK/OV circuit decomposition, and the induction-head mechanism for in-context learning; the superposition hypothesis explaining neuronal polysemanticity; the sparse autoencoder (SAE) approach for decomposing language model activations into monosemantic features; and the scaling of SAEs to the production model Claude 3 Sonnet, yielding millions of interpretable features. For each method, we present the core idea, key mathematical formulations, algorithmic details, and empirical results. The work is intended for researchers in the field of safety and interpretability of large language models.

Оглавление

Аннотация	1
Abstract	1
Введение	4
1 Обзор методов интерпретируемости	6
1.1 Суперпозиция в нейронных сетях	6
1.1.1 Признаки как направления в пространстве активаций	6
1.1.2 Гипотеза суперпозиции	6
1.1.3 Игрушечная модель: формальная постановка	7
1.1.4 Основные результаты: фазовый переход	8
1.1.5 Геометрия суперпозиции	9
1.1.6 Вычисления в суперпозиции	9
1.1.7 Выводы по теории суперпозиции	10
1.2 Разреженные автокодировщики для поиска моносемантических признаков	11
1.2.1 Мотивация: проблема полисемантичности	11
1.2.2 Гипотеза суперпозиции	11
1.2.3 Постановка задачи	12
1.2.4 Признаки как декомпозиция активаций	13
1.2.5 Архитектура разреженного автокодировщика	13
1.2.6 Функция потерь	15
1.2.7 Процедура обучения	16
1.2.8 Метрики оценки	17
1.2.9 Результаты: найденные признаки	18
1.2.10 Глобальный анализ	20
1.2.11 Феноменология признаков	21
1.2.12 Каузальное вмешательство в активации признаков . .	22
1.2.13 Интерфейс для анализа признаков	23
1.2.14 Обсуждение и ограничения	23

1.2.15	Выводы по методу	24
1.3	Масштабирование SAE: признаки Claude 3 Sonnet	25
1.3.1	Масштаб и задача	25
1.3.2	Архитектурные улучшения	25
1.3.3	Законы масштабирования для SAE	26
1.3.4	Примеры найденных признаков	27
1.3.5	Признаки как вычислительные промежуточные	28
1.3.6	Самопредставление модели	29
1.3.7	Универсальность признаков	29
1.3.8	Ограничения и открытые вопросы	30
1.3.9	Выводы по масштабированию	30
1.4	Математический фреймворк трансформерных цепей	31
1.4.1	Мотивация: от признаков к алгоритмам	31
1.4.2	Упрощения модели и нотация	32
1.4.3	Остаточный поток как коммуникационный канал	33
1.4.4	Головы внимания: QK- и OV-цепи	34
1.4.5	Нулевой трансформер (zero-layer)	35
1.4.6	Однослойный трансформер	36
1.4.7	Двухслойные трансформеры: типы композиции	37
1.4.8	Индукционные головы	39
1.4.9	Фазовые переходы и контекстное обучение	42
1.4.10	Выводы по методу	43
	Заключение	45
	Библиографический список	47
	А Глоссарий	48
	В Исходные данные экспериментов	49
	В.1 Протоколы	49
	С Листинги кода (фрагменты)	50

Введение

Языковые модели, основанные на архитектуре трансформера [1], достигли выдающихся результатов во многих задачах обработки естественного языка. Такие модели, как GPT, Qwen, Deepseek и им подобные, способны генерировать связный текст, решать задачи и писать код. Вместе с тем их внутренние механизмы остаются в значительной мере непрозрачными: модель представляет собой миллиарды числовых параметров, не поддающихся непосредственному человеческому анализу.

Механистическая интерпретируемость ставит перед собой цель «реверс инжиниринга» нейронных сетей, то есть понимания конкретных вычислительных механизмов, лежащих в основе наблюдаемого поведения. Это направление приобретает особую важность в контексте безопасности ИИ: систематическое понимание того, как именно модель принимает решения, позволяет обнаруживать нежелательное поведение, проверять соответствие целям разработчиков и предсказывать возможные сбои.

В данной работе рассматриваются взаимосвязанные направления механистической интерпретируемости, представленные в четырёх публикациях исследовательской группы Anthropic:

1. **A Mathematical Framework for Transformer Circuits** [2] — фундаментальный математический инструментарий: разложение вычислений трансформера на составные цепи (circuits), QK/OV-факторизация голов внимания, остаточный поток как канал связи и механизм индукционных голов как объяснение контекстного обучения.
2. **Toy Models of Superposition** [3] — теоретическая основа: почему нейроны языковых моделей полисемантичны и как явление суперпозиции объясняет эту полисемантичность на примере минималистичных игрушечных моделей.
3. **Towards Monosemanticity: Decomposing Language Models With Dictionary Learning** [4] — практический метод: разреженные автокодировщики (Sparse Autoencoders, SAE) для выделения интерпретируемых признаков из активаций MLP-слоёв трансформера.

4. **Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet** [5] — масштабирование подхода на промышленную языковую модель, получение миллионов признаков и демонстрация их связи с вопросами безопасности.

Четыре работы образуют связную исследовательскую программу: от математического языка для анализа алгоритмов трансформера — к теоретическому пониманию суперпозиции — к практическому методу её преодоления — к демонстрации, что этот метод работает на моделях класса frontier.

1 Обзор методов интерпретируемости

1.1 Суперпозиция в нейронных сетях

Данный раздел посвящён теоретическому фундаменту метода SAE — работе Elhage et al. [3] «Toy Models of Superposition» (Anthropic, 2022). Она объясняет, почему нейроны языковых моделей являются полисемантическими и как это явление возникает в процессе обучения.

1.1.1 Признаки как направления в пространстве активаций

Интерпретируемость нейронных сетей часто исходит из предположения, что каждый нейрон кодирует одну концепцию — так называемая **моносеманτικότητα**. Однако большинство нейронов в реальных сетях оказываются **полисемантическими**: они активируются на несколько семантически несвязанных понятий одновременно.

Авторы предлагают взглянуть на проблему иначе: вместо отдельных нейронов рассматривать **направления** в пространстве активаций как носители смысла.

Признак (feature) — линейное направление $\mathbf{d} \in \mathbb{R}^n$ в пространстве активаций, ассоциированное с некоторым семантически интерпретируемым свойством входа.

Это обобщение снимает принципиальное ограничение: число признаков не обязано совпадать с числом нейронов. Если n — ширина слоя, то существует ровно n ортогональных направлений — но сеть *может* хранить $m \gg n$ признаков в n -мерном пространстве, размещая их в неортогональных направлениях. Ценой этому служат взаимные помехи — суперпозиция.

1.1.2 Гипотеза суперпозиции

Суперпозиция — явление, при котором нейронная сеть представляет больше признаков, чем у неё нейронов, кодируя их через неортогональные

линейные комбинации.

Суперпозиция возможна при выполнении двух условий:

- **Разреженность:** каждый признак активен лишь на малой доле входов, поэтому вероятность одновременного «столкновения» двух признаков мала;
- **Приблизительная ортогональность:** признаки кодируются в направлениях, достаточно далёких друг от друга, что сводит взаимную интерференцию к минимуму.

Суперпозиция прямо порождает полисемантичесность. Нейрон — это проекция пространства активаций на одну координатную ось. При суперпозиции несколько признаков проецируются на каждый нейрон, поэтому нейрон «видит» несколько концепций сразу.

1.1.3 Игрушечная модель: формальная постановка

Для количественного изучения суперпозиции авторы вводят простейшую однослойную модель с нелинейностью ReLU:

$$\hat{\mathbf{x}} = \text{ReLU}(W^\top W \mathbf{x} + \mathbf{b}), \quad (1.1)$$

где $\mathbf{x} \in \mathbb{R}^n$ — входной вектор из n признаков, $W \in \mathbb{R}^{m \times n}$ ($m < n$) — матрица сжатия, $\mathbf{h} = W\mathbf{x} \in \mathbb{R}^m$ — скрытое «бутылочное горлышко», $\mathbf{b} \in \mathbb{R}^m$ — смещение.

Произведение $W^\top W \in \mathbb{R}^{n \times n}$ — матрица Грама столбцов W . Её диагональные элементы $(W^\top W)_{ii} = \|\mathbf{w}_i\|^2$ отражают качество представления i -го признака, а внедиагональные $(W^\top W)_{ij} = \mathbf{w}_i^\top \mathbf{w}_j$ — интерференцию между признаками i и j .

Генерация данных. Признаки генерируются независимо: с вероятностью $(1 - s)$ признак равен 0, иначе — равномерно из $[0, 1]$. Параметр $s \in [0, 1]$ — **плотность** признаков ($s = 0$: полностью разреженные, $s = 1$: плотные).

Функция потерь. Оптимизация ведётся по взвешенной ошибке реконструкции:

$$\mathcal{L} = \sum_{i=1}^n I_i \cdot \mathbb{E}[(x_i - \hat{x}_i)^2], \quad (1.2)$$

где $I_i > 0$ — **важность** i -го признака. В экспериментах используется геометрически убывающая схема $I_i = r^{i-1}$ ($r < 1$), имитируя реальные частотные распределения концептов в тексте.

1.1.4 Основные результаты: фазовый переход

Ключевое наблюдение работы [3]: оптимальная стратегия представления резко меняется в зависимости от плотности s и важностей I_i .

Три режима.

1. **Моносемантичность:** топ- m признаков получают выделенные нейроны (ортогональные оси), остальные игнорируются. Оптимально при низкой разреженности или высокой важности.
2. **Суперпозиция:** все $n > m$ признаков хранятся через неортогональные направления. Оптимально при высокой разреженности.
3. **Смешанный режим:** часть признаков моносемантична, часть — в суперпозиции.

Условие перехода. Для двух признаков с косинусным сходством $\cos \theta = \mathbf{w}_i^\top \mathbf{w}_j$ сеть предпочитает держать дополнительный признак в суперпозиции при:

$$s < s^* \approx \frac{I_1 - I_2}{I_1 \cdot \cos^2 \theta}. \quad (1.3)$$

При плотных признаках ($s \rightarrow 1$) интерференция высока — суперпозиция невыгодна. При разреженных ($s \rightarrow 0$) — столкновения редки, суперпозиция выгодна: выигрыш от хранения дополнительного признака превышает среднюю помеху.

1.1.5 Геометрия суперпозиции

Один из наиболее красивых результатов работы состоит в том, что оптимальные конфигурации суперпозиции образуют **правильные геометрические фигуры**.

При $m = 2$ нейронах и n признаках с одинаковой важностью и разреженностью оптимальное решение представляет собой равномерно расположенные точки на единичной окружности:

- $n = 2$: два антиподальных направления (0 и 180);
- $n = 3$: вершины правильного треугольника (угол 120);
- $n = 5$: вершины правильного пятиугольника (угол 72).

В трёхмерном и многомерном пространствах признаки стремятся образовывать вершины правильных многогранников — икосаэдров, симплексов и т. д.

Фракционная размерность. Авторы вводят понятие **фракционной размерности** признака:

$$D_i = \frac{\|\mathbf{w}_i\|^4}{\sum_j (\mathbf{w}_i^\top \mathbf{w}_j)^2}. \quad (1.4)$$

Если признак моносемантичен (занимает выделенный нейрон) — $D_i \approx 1$. При суперпозиции — $D_i < 1$: признак занимает «долю нейрона».

1.1.6 Вычисления в суперпозиции

Суперпозиция — это не только способ хранения информации, но и вычислений. Авторы [3] демонстрируют, что двухслойные MLP с ReLU способны реализовывать логические операции непосредственно над суперпозиционными признаками:

- **AND**: выход активируется только при совместной активации двух признаков. Достигается за счёт того, что сумма двух суперпозици-

онных векторов превышает порог ReLU лишь при их одновременном присутствии.

- **OR**: выход активируется при наличии хотя бы одного из признаков.

Это означает, что языковые модели могут осуществлять нетривиальные вычисления, не «разворачивая» суперпозицию в явные моносемантические нейроны — и именно поэтому без специальных инструментов (SAE) интерпретировать их так трудно.

Связь с состязательными примерами. Работа [3] также показывает, что суперпозиция порождает уязвимость к adversarial examples: малое возмущение входа, направленное вдоль «чужого» суперпозиционного признака, создаёт ложную активацию этого признака. При строго ортогональных (моносемантических) признаках такой атаки невозможно.

1.1.7 Выводы по теории суперпозиции

Работа «Toy Models of Superposition» устанавливает следующее:

1. Полисеманτικότητα нейронов — не случайный артефакт, а закономерный результат оптимизации: суперпозиция позволяет хранить больше признаков за счёт использования разреженности.
2. Существует **фазовый переход**: при высокой разреженности признаков суперпозиция является оптимальной стратегией, при низкой — нет.
3. Оптимальные конфигурации суперпозиции образуют правильные геометрические структуры (правильные многогранники).
4. Суперпозиция допускает нетривиальные вычисления, оставаясь при этом непрозрачной для нейронного анализа.

Именно эти результаты мотивируют метод разреженных автокодировщиков: если признаки разрежены и линейны, то их можно «извлечь» из суперпозиции, обучив словарь, который явно их разделяет.

1.2 Разреженные автокодировщики для поиска моносемантических признаков

Данный раздел посвящён методу, предложенному в работе Bricken et al. [4] «Towards Monosemanticity: Decomposing Language Models With Dictionary Learning» (Anthropic, 2023). Метод направлен на решение фундаментальной проблемы механистической интерпретируемости — полисемантической нейронов языковых моделей — с помощью разреженных автокодировщиков (Sparse Autoencoder, SAE).

1.2.1 Мотивация: проблема полисемантической

Центральная проблема механистической интерпретируемости состоит в том, что нейроны нейронных сетей, как правило, являются **полисемантическими**: один нейрон активируется на несколько семантически несвязанных концепций. Авторы приводят наглядный пример из однослойного трансформера: нейрон 2 049 MLP-слоя сильно активируется на токены, относящиеся к академическим цитатам, переводам, фрагментам прозы в кавычках, обозначениям времени в японском тексте и последовательностям ДНК — совершенно разнородный набор концепций.

Такая полисеманτικότητα существенно затрудняет интерпретацию: даже если исследователь изучает активацию отдельного нейрона, он не может установить, какой именно концепт этот нейрон «видит» в конкретном контексте.

Ключевой гипотезой, объясняющей это явление, служит **гипотеза суперпозиции**.

1.2.2 Гипотеза суперпозиции

Гипотеза суперпозиции [3] утверждает, что нейронные сети представляют *больше признаков*, чем у них имеется нейронов, кодируя эти признаки через линейные комбинации нейронов. Это возможно, если выполняются два условия:

- **Разреженность признаков:** каждый признак активен лишь на малой доле входных данных, поэтому вероятность одновременной активации двух «соседних» признаков невелика;
- **Приблизительная ортогональность:** признаки кодируются в направлениях, которые примерно ортогональны друг другу, что минимизирует взаимную интерференцию.

Игрушечная модель суперпозиции [3] демонстрирует: при обучении линейной сети с n нейронами представлять $m > n$ разреженных признаков сеть «упаковывает» все признаки в суперпозицию, жертвуя точностью, но выигрывая в ёмкости. Форма хранения зависит от соотношения m/n и уровня разреженности: при высокой разреженности признаки образуют примерно правильные многогранники в n -мерном пространстве.

Таким образом, полисемантичность нейронов является *не случайным артефактом обучения*, а предсказуемым следствием суперпозиции: нейрон одновременно участвует в представлении нескольких признаков.

1.2.3 Постановка задачи

Авторы исследуют **однослойный трансформер** с 512-мерным пространством активаций ($d = 512$), обученный на корпусе The Pile [6]. Объектом анализа служат **post-ReLU активации MLP-слоя**: вектор $\mathbf{x} \in \mathbb{R}^n$, где $n = 512$ — число нейронов в расширенном пространстве MLP ($d_{\text{MLP}} = 4d = 2048$, но авторы обозначают анализируемое измерение через n).

Задача формулируется следующим образом: найти **словарь признаков** из $m \gg n$ элементов — набор направлений $\{\mathbf{d}_i\}_{i=1}^m$ в пространстве $\mathbb{R}^n$ — такой, что каждый вектор активаций $\mathbf{x}$ может быть приближённо представлен через небольшое число активных признаков:

$$\mathbf{x} \approx \mathbf{b}_{\text{dec}} + \sum_{i=1}^m f_i(\mathbf{x}) \cdot \mathbf{d}_i, \quad (1.5)$$

где $f_i(\mathbf{x}) \geq 0$ — скалярное значение активации i -го признака, $\mathbf{b}_{\text{dec}}$ — смещение, и при этом большинство $f_i(\mathbf{x})$ равны нулю (разреженность).

1.2.4 Признаки как декомпозиция активаций

Прежде чем перейти к архитектуре SAE, авторы формализуют понятие **хорошей декомпозиции**. Согласно статье, декомпозиция активаций является качественной, если:

1. **Точность**: восстановленные активации $\hat{\mathbf{x}}$ близки к исходным $\mathbf{x}$ (малая ошибка реконструкции);
2. **Разреженность**: среднее число ненулевых признаков на токен (L_0 -норма) мало — в идеале от 1 до нескольких десятков;
3. **Интерпретируемость**: каждый найденный признак активируется на семантически однородном множестве токенов и поддается человеческому объяснению;
4. **Универсальность**: признаки, найденные независимыми запусками обучения, воспроизводят друг друга (т.е. не являются артефактами конкретной инициализации).

Авторы обосновывают, почему нельзя использовать отдельные нейроны как «признаки»: полисемантичность означает, что направление нейрона не соответствует ни одной интерпретируемой концепции. PCA и ICA также не подходят: главные компоненты не разрежены и не соответствуют семантическим концептам. Кластеризация не применима, поскольку один токен может активировать несколько признаков одновременно. Метод NMF требует неотрицательности исходных данных. Оптимальным решением оказывается **разреженное кодирование** на переполненном (overcomplete) словаре.

1.2.5 Архитектура разреженного автокодировщика

SAE состоит из энкодера и декодера с общим промежуточным пространством размерности m .

Энкодер. Энкодер принимает вектор активаций $\mathbf{x} \in \mathbb{R}^n$, вычитает декодерное смещение и применяет аффинное преобразование с функцией активации ReLU:

$$\mathbf{f}(\mathbf{x}) = \text{ReLU}(\mathbf{W}_{\text{enc}}(\mathbf{x} - \mathbf{b}_{\text{dec}}) + \mathbf{b}_{\text{enc}}), \quad (1.6)$$

где $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{m \times n}$ — матрица весов энкодера, $\mathbf{b}_{\text{enc}} \in \mathbb{R}^m$ — смещение энкодера, $\mathbf{b}_{\text{dec}} \in \mathbb{R}^n$ — смещение декодера (вычитается до кодирования), а $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^m$ — вектор активаций признаков.

Декодер. Декодер линейно восстанавливает исходный вектор из активаций признаков:

$$\hat{\mathbf{x}} = \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) + \mathbf{b}_{\text{dec}}, \quad (1.7)$$

где $\mathbf{W}_{\text{dec}} \in \mathbb{R}^{n \times m}$. Столбцы матрицы декодера обозначаются $\mathbf{d}_i \in \mathbb{R}^n$ и называются **атомами словаря** (dictionary atoms): каждый $\mathbf{d}_i$ задаёт направление i -го признака в пространстве активаций.

Ограничение на норму. Принципиальным архитектурным решением является требование **единичной нормы** столбцов декодера:

$$\|\mathbf{d}_i\|_2 = 1 \quad \forall i \in \{1, \dots, m\}. \quad (1.8)$$

Это ограничение предотвращает вырожденное решение, при котором декодерные веса уменьшаются до нуля, а энкодер компенсирует это произвольно большими активациями. Нормировка обеспечивает, что каждый атом словаря является *единичным направлением*, а масштабная информация полностью сосредоточена в значениях $f_i(\mathbf{x})$.

Дизайнерские решения.

- **Pre-bias subtraction (вычитание смещения до кодирования).**

Декодерное смещение $\mathbf{b}_{\text{dec}}$ аппроксимирует среднее значение вектора активаций по всему датасету. Вычитая его перед кодированием, авторы центрируют данные относительно их среднего, позволяя энкодеру фокусироваться на отклонениях от среднего — именно они несут структурированную семантическую информацию.

- **Отсутствие разделения весов (no weight tying).** В отличие от классических автокодировщиков, где $\mathbf{W}_{\text{enc}} = \mathbf{W}_{\text{dec}}^\top$, в SAE $\mathbf{W}_{\text{enc}}$ и $\mathbf{W}_{\text{dec}}$ полностью независимы. Это позволяет энкодеру и декодеру использовать различные геометрические представления одного и того же пространства признаков.
- **ReLU как механизм разреженности.** Функция ReLU обнуляет отрицательные активации, обеспечивая неотрицательность $\mathbf{f}(\mathbf{x})$ и вводя неявную разреженность: лишь те признаки, у которых предактивационное значение положительно, участвуют в реконструкции.

1.2.6 Функция потерь

SAE обучается минимизировать следующую функцию потерь:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{ошибка реконструкции}} + \lambda \underbrace{\|\mathbf{f}(\mathbf{x})\|_1}_{\text{штраф за плотность}}, \quad (1.9)$$

где $\lambda > 0$ — коэффициент регуляризации, управляющий компромиссом между точностью реконструкции и разреженностью активаций признаков.

Ошибка реконструкции (L_2). Первое слагаемое принуждает SAE точно восстанавливать исходные активации. Если бы оно было единственным, модель свелась бы к полному представлению $\mathbf{x}$ через $\mathbf{f}(\mathbf{x})$ без каких-либо ограничений разреженности.

L_1 -штраф. Второе слагаемое штрафует за сумму абсолютных значений активаций признаков, поощряя решения, в которых большинство $f_i(\mathbf{x})$ равны нулю. Норма L_1 является **выпуклой релаксацией** нормы L_0 (числа ненулевых компонент) и при этом остаётся дифференцируемой, что допускает обучение градиентными методами.

Роль гиперпараметра λ .

- При малом λ : SAE точно восстанавливает $\mathbf{x}$, но признаки плотные и плохо интерпретируемые;

- При большом λ : признаки разреженные, но реконструкция неточная (теряется часть информации об активациях);
- Оптимальное λ находится эмпирически, ориентируясь на метрики интерпретируемости и качества реконструкции.

Полная функция потерь, усреднённая по батчу токенов:

$$\mathcal{L} = \mathbb{E}_{\mathbf{x}} \left[\|\mathbf{x} - \mathbf{W}_{\text{dec}} \mathbf{f}(\mathbf{x}) - \mathbf{b}_{\text{dec}}\|_2^2 + \lambda \sum_{i=1}^m f_i(\mathbf{x}) \right]. \quad (1.10)$$

1.2.7 Процедура обучения

Данные. SAE обучается на активациях, собранных заранее при прогоне однослойного трансформера на случайных токенах из корпуса The Pile [6] — открытого датасета объёмом ~ 800 ГБ, охватывающего широкий спектр текстовых жанров и языков. Обучение SAE ведётся отдельно от обучения языковой модели — на зафиксированных активациях.

Размеры словарей. Авторы обучают семейство SAE с различными коэффициентами расширения m/n : $1\times$, $2\times$, $4\times$, $8\times$, $16\times$, $32\times$ относительно $n = 512$. Это даёт словари от 512 до 16 384 признаков. Основные результаты получены на словаре $m = 4096$ ($8\times$).

Оптимизация. Используется оптимизатор Adam. Нормировка столбцов декодера поддерживается на каждом шаге через проецирование градиента: после шага оптимизатора все столбцы $\mathbf{d}_i$ нормируются на единичную длину, что реализует ограничение (1.8).

«Мёртвые» признаки. В процессе обучения часть признаков может так и не начать активироваться («мёртвые» признаки, *dead features*). Это происходит из-за того, что градиент через неактивные нейроны ReLU равен нулю. Авторы используют эвристику периодической переинициализации мёртвых признаков, которая помогает задействовать неиспользуемые атомы словаря.

1.2.8 Метрики оценки

Авторы предлагают комплексную систему оценки качества обученного SAE.

Качество реконструкции

- **L_2 -ошибка:** $\mathbb{E}[\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2]$ — среднеквадратическое отклонение восстановленных активаций от исходных.
- **Доля объяснённых потерь** (fraction of loss recovered): насколько использование $\hat{\mathbf{x}}$ вместо $\mathbf{x}$ изменяет cross-entropy потери языковой модели. Если подставить реконструкции SAE обратно в модель вместо исходных активаций MLP, деградация потерь показывает, сколько информации утеряно при кодировании.

Разреженность

- **L_0 -норма:** среднее число ненулевых активаций $f_i(\mathbf{x})$ на токен. Является прямой мерой разреженности: чем меньше, тем более сжатым является представление. Для словаря 4 096 признаков авторы достигают $L_0 \approx 25$ — в среднем на токен активируется лишь 25 из 4096 признаков ($\approx 0.6\%$).
- **L_1 -норма:** $\mathbb{E}[\|\mathbf{f}(\mathbf{x})\|_1]$ — используется в функции потерь, менее информативна для интерпретации.

Интерпретируемость

Это наиболее важная и нетривиальная метрика, для оценки которой авторы разработали двухуровневый подход.

Ручная оценка. Исследователи изучают каждый признак вручную:

1. Отбираются токены с наибольшей активацией $f_i(\mathbf{x})$ (топ-10–20 по значению);
2. Выводится контекст каждого токена (окно в 20–30 символов);

3. Исследователь формулирует гипотезу о том, что именно активирует признак;
4. Гипотеза проверяется на случайных токенах с высокой активацией.

Автоматическая интерпретируемость. Авторы применяют языковую модель (GPT-4 или Claude) для автоматизации процесса:

1. Для данного признака i отбираются k токенов с наибольшей активацией (положительные примеры) и k токенов с нулевой активацией (отрицательные примеры);
2. Языковая модель генерирует *объяснение* — гипотезу о семантике признака;
3. На отдельной выборке из k' токенов (удерживаемой выборке) языковую модель просят предсказать, будет ли признак активен для каждого токена;
4. Вычисляются **detection score** (доля правильно угаданных активаций) и **false positive rate** (доля ложноположительных срабатываний).

Чем выше detection score при низком false positive rate, тем более точным и специфичным является объяснение признака.

1.2.9 Результаты: найденные признаки

Словарь из 4 096 признаков (8×-расширение) демонстрирует богатое разнообразие интерпретируемых концептов. Авторы описывают подробно несколько категорий.

Базовые числовые признаки.

- *Base-10 digits*: активируется на цифры 0–9 вне зависимости от контекста;

- *Arabic numerals in non-Latin scripts*: арабские числа, встречающиеся внутри текстов на нелатинских системах письма (например, в персидских или арабских текстах);
- *Numbers in decimal fractions*: числа, выступающие в роли дробной части десятичной записи.

Биологические и научные признаки.

- *DNA sequences*: активируется на токены внутри последовательностей нуклеотидов (ATCG...); является одним из наиболее часто цитируемых примеров в статье как демонстрация специфичности найденных признаков;
- *Periodic table elements*: символы химических элементов;
- *Mathematical notation*: математические символы и обозначения.

Лингвистические признаки.

- *Hebrew text*: токены в тексте на иврите;
- *Arabic script*: арабское письмо;
- *Cyrillic text*: кириллица;
- *Legal language*: юридические термины и формулировки.

Программный код.

- *Function arguments*: имена аргументов функций в коде;
- *Variable assignment*: оператор присваивания в различных языках программирования;
- *Python import statements*: инструкции импорта в Python.

Академический и публикационный стиль.

- *Academic citations*: токены в академических ссылках (например, «et al.», «ibid.», номера страниц в скобках);
- *Bible quotations*: фрагменты библейских текстов;
- *Prose quotations*: цитаты в художественных текстах.

Авторы подчёркивают: признаки, выявленные SAE, *значительно более моносемантчны*, чем исходные нейроны. Большинство топ-активирующих токенов для каждого признака относятся к семантически однородной категории, и эксперты-люди без труда формулируют объяснение.

1.2.10 Глобальный анализ

Помимо анализа отдельных признаков, авторы исследуют глобальные свойства выученного словаря.

Распределение частот активации

Частота активации признаков ($\rho_i = P(f_i(\mathbf{x}) > 0)$) распределена приближённо по степенному закону: большинство признаков редкие ($\rho_i < 0.1\%$), и лишь немногие активируются на значительной доле токенов. Такое распределение согласуется с предположением о разреженности: признаки соответствуют специфическим концептам, которые встречаются в тексте нечасто.

Дробление признаков (Feature Splitting)

При увеличении размера словаря от $1\times$ до $32\times$ наблюдается **дробление признаков**: признак, представлявший в малом словаре широкую концепцию, в большем словаре разбивается на несколько более специфических подпризнаков. Например:

- Словарь 512: один признак «числа»;

- Словарь 4 096: признаки «арабские числа», «числа в скобках», «числа в десятичных дробях», «числа в временных обозначениях» и т. д.

Дробление свидетельствует о том, что SAE выявляет иерархическую структуру признакового пространства и что большие словари действительно «открывают» новые, более тонкие различия.

Универсальность признаков (Feature Universality)

Сравнение признаков, выученных в разных запусках SAE (с различными инициализациями и разными коэффициентами расширения), показывает высокую степень **воспроизводимости**. Признаки, найденные в одном словаре, имеют хорошо выраженный «двойник» в другом словаре (высокая косинусная близость атомов $\mathbf{d}_i$). Это говорит о том, что признаки отражают реальную структуру активационного пространства, а не являются артефактами конкретного обучения.

«Мёртвые» признаки

Часть атомов словаря остаётся «мёртвой» (dead features) — никогда не активируется в течение оценочного периода. При 8×-расширении доля мёртвых признаков составляет порядка 20–30%. Авторы интерпретируют это как ограничение текущего метода обучения, а не как свидетельство того, что в активациях нет дополнительных структур.

1.2.11 Феноменология признаков

Авторы проводят детальный анализ нескольких признаков, демонстрируя типичный паттерн. Для каждого признака строится:

- **Гистограмма активаций:** крайне правостороннее распределение — большинство токенов дают нулевую активацию, и лишь единичные токены показывают высокие значения;
- **Scatter-plot:** активации на осях двух признаков (показывает слабую корреляцию между признаками — признак независимости);

- **Список топ-токенов:** контексты с наибольшей активацией, позволяющие оценить семантику признака;
- **Список анти-токенов:** контексты с наиболее отрицательным преактивационным значением (до ReLU) — то, что «противоположно» признаку.

Анализ подтверждает: признаки с высоким detection score имеют чёткую семантику, однородные топ-токены и статистически значимую отделимость от фона.

1.2.12 Каузальное вмешательство в активации признаков

Одним из ключевых вопросов является: *являются ли найденные признаки реальными вычислительными единицами, влияющими на поведение модели?* Корреляция признака с токенами ещё не означает каузальности.

Для ответа авторы проводят **интервенционные эксперименты** (feature steering):

1. Выбирается признак i с известной семантикой;
2. При прогоне токена t активация признака искусственно фиксируется: $f_i(\mathbf{x}) \leftarrow c$ (где c значительно превышает естественный уровень);
3. Наблюдается изменение распределения следующего токена (вывода модели).

Результаты показывают, что принудительная активация признака вызывает *предсказуемое и семантически согласованное* изменение вывода. Например, активация признака «DNA sequences» побуждает модель генерировать нуклеотидные последовательности. Это подтверждает, что найденные признаки — не просто корреляты, а **каузально значимые вычислительные единицы** языковой модели.

1.2.13 Интерфейс для анализа признаков

Авторы создают **интерактивный веб-интерфейс** для просмотра обученных признаков. Интерфейс позволяет:

- Просматривать топ-токены для каждого признака;
- Искать признаки по ключевым словам (например, ввести «DNA» и найти соответствующий признак);
- Изучать корреляции между признаками;
- Видеть предсказания автоматической интерпретируемости.

Доступность такого инструмента существенно упрощает дальнейшие исследования и проверку интерпретируемости.

1.2.14 Обсуждение и ограничения

Масштабируемость

Основным ограничением работы является масштаб: SAE обучается на *однослойном* трансформере с 512-мерными активациями. Применение метода к современным многослойным моделям (например, GPT-4 или Claude с тысячами измерений) требует значительно большего вычислительного ресурса и может потребовать новых архитектурных решений.

«Является ли контекст признаком?»

Авторы обсуждают философский вопрос: некоторые «признаки» кодируют не столько семантику *токена*, сколько *контекст*. Например, признак может активироваться не на сам токен «ATCG», а на любой токен в тексте, содержащем последовательность ДНК. Это разграничение важно для понимания того, что именно представляют признаки — локальную или глобальную информацию.

Дополнительные свойства.

- **Признаки сами могут быть полисемантическими:** в малых словарях один признак объединяет семантически различные, но статистически коррелирующие концепты. Дробление при увеличении словаря частично решает эту проблему.
- **Влияние на кросс-энтропию:** подстановка реконструкций SAE вместо исходных активаций увеличивает кросс-энтропийные потери языковой модели, что указывает на неизбежные потери информации при сжатии. Авторы показывают, что большие словари дают меньшие потери.
- **Связь с нейронауками:** метод разреженного кодирования восходит к классической модели Olshausen & Field [7] представления зрительной коры V1 через разреженный базис, что придаёт подходу дополнительную биологическую мотивацию.

1.2.15 Выводы по методу

Работа «Towards Monosemanticity» вносит существенный вклад в механистическую интерпретируемость, демонстрируя:

1. Разреженные автокодировщики позволяют декомпонировать полисемантические нейронные активации в более интерпретируемое пространство моносемантических признаков;
2. Функция потерь (1.9) обеспечивает баланс между точностью реконструкции и разреженностью при контролируемом λ ;
3. Выученные признаки каузально влияют на поведение модели (feature steering);
4. Увеличение размера словаря приводит к дроблению признаков и росту интерпретируемости;
5. Автоматическая оценка интерпретируемости с помощью языковых моделей позволяет масштабировать анализ на тысячи признаков.

1.3 Масштабирование SAE: признаки Claude 3 Sonnet

Данный раздел посвящён работе Templeton et al. [5] «Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet» (Anthropic, 2024). Она масштабирует подход SAE с однослойного трансформера на промышленную языковую модель и демонстрирует, что интерпретируемость достижима при миллионах признаков.

1.3.1 Масштаб и задача

Эксперименты проводились на **Claude 3 Sonnet** — фронтальной языковой модели с многомиллиардным числом параметров. SAE применялся к **residual stream** после 16-го трансформерного блока (из 48), с размерностью $d = 4096$.

Диапазон словарей: $M \in \{1K, 4K, 16K, 65K, 262K, 1M, 4M, 16M\}$. Для обучения использовалось 4×10^9 токенов — смесь английского, многоязычного и кодового контента.

1.3.2 Архитектурные улучшения

Проблема L_1 -регуляризации: shrinkage

L_1 -штраф, использованный в [4], имеет известный недостаток — **shrinkage**: систематическое занижение амплитуд активных признаков. Поскольку L_1 штрафует *любую* ненулевую активацию, даже «выжившие» признаки оказываются с заниженными значениями $f_j(\mathbf{x})$.

ТопК-разреженность

Вместо L_1 авторы [5] применяют **ТопК-активацию**:

$$\mathbf{f}(\mathbf{x}) = \text{ТопК}(W_{\text{enc}}(\mathbf{x} - \mathbf{b}_{\text{pre}}) + \mathbf{b}_{\text{enc}}), \quad (1.11)$$

где $\text{ТопК}(\mathbf{z})$ оставляет K наибольших положительных компонент, обнуляя остальные.

Преимущества по сравнению с L_1 :

- **Нет shrinkage:** ненулевые признаки не «прижимаются» штрафом;
- **Точный контроль:** $L_0 = K$ по определению — не нужно подбирать λ , чтобы получить нужную разреженность;
- **Стабильность обучения:** устраняется необходимость в балансировке гиперпараметра λ .

Также рассматривается **JumpReLU**:

$$\text{JumpReLU}_\theta(z) = \begin{cases} z, & z \geq \theta, \\ 0, & z < \theta, \end{cases} \quad (1.12)$$

где порог θ является обучаемым параметром. JumpReLU обеспечивает жёсткое «выключение» нейронов и при этом допускает градиентное обучение через STE (straight-through estimator).

1.3.3 Законы масштабирования для SAE

Авторы обнаруживают, что качество SAE описывается **степенным законом**:

$$\mathcal{L}_{\text{recon}}(M) \propto M^{-\alpha}, \quad \alpha \approx 0.5\text{--}0.7, \quad (1.13)$$

то есть ошибка реконструкции убывает по степенному закону от размера словаря — аналогично законам масштабирования для самих языковых моделей. Это означает, что каждое удвоение словаря приносит предсказуемое уменьшение ошибки.

CE loss gap. Практически важная метрика — **Cross-Entropy loss gap**: насколько деградируют предсказания языковой модели, если заменить её внутренние активации на реконструированные из SAE. При $M \approx 1\text{М}$ признаков разрыв становится пренебрежимо малым, то есть SAE практически полностью описывает вычисления модели.

Feature splitting. При увеличении M наблюдается **расщепление признаков**: крупный признак (например, «код на Python») разделяется на более тонкие («функции Python», «классы Python», «импорты Python»). Это отражает реальную иерархическую структуру данных, а не артефакт обучения.

1.3.4 Примеры найденных признаков

«Мост Золотые Ворота»

Один из наиболее известных примеров статьи — признак, соответствующий концепту «Мост Золотые Ворота» (Golden Gate Bridge). Примечательно его мультимодальное поведение: признак активируется одновременно на:

- текстовые упоминания моста в любом контексте;
- изображения моста (в мультимодальных промптах);
- метафорические употребления («мост между культурами»);
- смежные концепты — Сан-Франциско, подвесные мосты.

Для проверки каузальности авторы провели **эксперимент по управлению** (steering): искусственная активация признака с амплитудой $\alpha \gg 0$:

$$\mathbf{x}' = \mathbf{x} + \alpha \cdot \mathbf{d}_j, \quad (1.14)$$

где $\mathbf{d}_j$ — направление признака в residual stream. При высоком α модель начинала неуместно упоминать мост в любом контексте и описывала себя как мост — демонстрируя прямое каузальное влияние признака на поведение.

Признаки, связанные с безопасностью

Особую практическую значимость имеет обнаружение признаков, релевантных для задач безопасности:

- **Prompt injection**: признак активируется на попытки встроить скрытые инструкции во входные данные.

- **Манипуляция и обман:** признак на контексты, содержащие манипулятивные паттерны.
- **Нежелательный контент:** кластер признаков, связанных с потенциально вредоносными темами.
- **Угодливость (sycophancy):** признаки на паттерны чрезмерного согласия с пользователем.

Обнаружение этих признаков открывает возможности для целенаправленного аудита: вместо случайного red-teaming можно напрямую проверить, при каких условиях активируются потенциально опасные признаки, и отследить их причинно-следственные эффекты на поведение модели.

Признаки личностей и абстрактных концептов

SAE выявил признаки для более 400 известных личностей — учёных, политиков, писателей — каждый из которых активируется на имя, связанные события и биографические факты данного человека.

Обнаружен признак «синдрома самозванца» — психологически тонкий концепт, активирующийся на контексты неуверенности в собственной компетентности, что демонстрирует способность SAE извлекать понятия высокого уровня абстракции.

1.3.5 Признаки как вычислительные промежуточные

Работа [5] идёт дальше простой детекции признаков и показывает, что признаки SAE участвуют в **вычислительных цепочках** внутри модели.

Пример: географический вывод. При обработке токена «Берлин» прослеживается цепочка:

«Берлин» → признак «немецкий город» → признак «столица» → усиление

Метод проверки. Для верификации каузальной цепочки используется **activation patching**: активация признака j в слое l заменяется на акти-

вацию из другого примера, и наблюдается изменение финального предсказания. Если признак каузально значим — замена изменит предсказание предсказуемым образом.

1.3.6 Самопредставление модели

Среди найденных признаков — признаки, связанные с тем, как модель представляет саму себя:

- Признак «Claude identity»: активируется при упоминании имени модели и при рефлексивных вопросах о её природе.
- Признаки ограничений и возможностей: кодируют, что модель считает допустимым или недопустимым.
- Признаки ролевой структуры диалога: «Assistant», «User», системный промпт.

Интересно, что признаки самоидентификации Claude пространственно близки к признакам ограничений безопасности — это согласуется с гипотезой, что RLHF встраивает концепцию безопасного поведения в «самопредставление» модели.

1.3.7 Универсальность признаков

Авторы проверяют, воспроизводятся ли признаки, найденные в одной модели, в других. Результаты:

- Большинство высокоуровневых семантических признаков (личности, концепты, синтаксические паттерны) воспроизводятся во всех трёх моделях семейства Claude 3 (Haiku, Sonnet, Opus), что указывает на их связь со структурой обучающих данных, а не с конкретной архитектурой.
- Признаки сохраняются при RLHF fine-tuning: настройка меняет *веса* признаков в вычислениях, но не их *направления* в пространстве активаций.

1.3.8 Ограничения и открытые вопросы

Проблема валидации

Не существует строгого критерия, позволяющего убедиться, что найденные признаки являются «истинными» вычислительными объектами модели, а не артефактами SAE. Ablation и steering дают каузальные свидетельства, но применялись лишь к малой доле признаков.

Полнота

Малый CE loss gap гарантирует точность *реконструкции*, но не то, что SAE интерпретирует *все* функционально значимые паттерны. Часть вычислений может быть закодирована нелинейно — вне линейной модели признаков.

Feature absorption

При недостаточном размере словаря SAE может «поглощать» два коррелирующих признака в один: признак A оказывается закодирован не отдельно, а только в связке $A + B$. Это нарушает моносемантичесность и затрудняет интерпретацию.

Вычислительная стоимость

Матрица $W_{\text{enc}} \in \mathbb{R}^{16M \times 4096}$ требует ≈ 250 ГБ памяти в float16. Inference SAE добавляет $\mathcal{O}(M \cdot d)$ операций на каждый токен, что существенно при промышленном развёртывании.

1.3.9 Выводы по масштабированию

Работа «Scaling Monosemanticity» демонстрирует:

1. Метод SAE масштабируется на промышленные LLM: при $M \approx 1\text{M}$ признаков CE loss gap становится пренебрежимо малым.
2. Качество реконструкции подчиняется степенному закону (1.13), что позволяет предсказывать и планировать масштабирование.

3. Среди признаков обнаруживаются объекты, непосредственно важные для задач безопасности (prompt injection, манипуляция, опасный контент).
4. Признаки являются каузально значимыми вычислительными объектами: их управление через steering влечёт предсказуемые изменения поведения.
5. Топ-К активация превосходит L1-регуляризацию по качеству и удобству управления.

1.4 Математический фреймворк трансформерных цепей

Данный раздел посвящён работе Elhage et al. [2] «A Mathematical Framework for Transformer Circuits» (Anthropic, 2021). Статья закладывает математический язык для **circuit-level** анализа трансформеров: вместо вопроса «что закодировано в нейронах?» она ставит вопрос «*как именно* трансформер реализует тот или иной алгоритм?». Метод позволяет точно разложить вычисление модели на независимые вклады отдельных компонентов и тем самым идентифицировать конкретные механизмы, ответственные за наблюдаемое поведение.

1.4.1 Мотивация: от признаков к алгоритмам

Механистическая интерпретируемость преследует двойную цель: понять *что* представлено в активационном пространстве (признаки) и *как* это представление используется для вычислений (алгоритмы). Работы по разреженным автокодировщикам [4; 5] отвечают на первый вопрос, выявляя моносемантические признаки в активациях отдельных слоёв. Однако для полного понимания недостаточно знать словарь концептов — необходимо понимать, как они взаимодействуют между слоями и как складываются в итоговое предсказание.

Авторы [2] ставят задачу «реверс-инжиниринга» конкретных вычислительных механизмов. Центральный объект исследования — **цепь** (circuit): минимальный подграф вычислительного графа трансформера, реализующий конкретную функцию. Для точного математического описания цепей авторы вводят ряд упрощений и новую нотацию, сохраняя при этом ключевые феномены реальных моделей.

1.4.2 Упрощения модели и нотация

Для получения аналитически tractable результатов авторы принимают четыре упрощающих предположения.

Отсутствие смещений. Все bias-вектора в слоях внимания и MLP полагаются равными нулю. Это существенно упрощает матричные выражения, не меняя качественного поведения механизмов.

Связанные матрицы эмбединга. Матрица входного эмбединга $W_E \in \mathbb{R}^{d_{\text{model}} \times |V|}$ и матрица унэмбединга $W_U \in \mathbb{R}^{|V| \times d_{\text{model}}}$ предполагаются транспозицией друг друга: $W_U = W_E^\top$. На практике такое «связывание весов» использовалось в ранних моделях и упрощает анализ произведений $W_E W_E^\top$.

Фокус на attention-only трансформерах. Для теоретического анализа авторы рассматривают модели *без MLP-слоёв*. Это позволяет получить замкнутые формулы для полного вычисления и сосредоточиться на механизмах внимания. Реальные трансформеры содержат MLP-слои, однако ключевые феномены (индукционные головы, QK/OV-цепи) воспроизводятся и в этой упрощённой постановке.

Нотация.

- d_{model} — размерность остаточного потока (residual stream);
- $|V|$ — размер словаря (vocabulary);
- n_{heads} — число голов внимания в каждом слое;

- $d_{\text{head}} = d_{\text{model}}/n_{\text{heads}}$ — размерность одной головы;
- L — число слоёв трансформера;
- $W_Q^h, W_K^h \in \mathbb{R}^{d_{\text{head}} \times d_{\text{model}}}$ — матрицы запросов и ключей для головы h ;
- $W_V^h \in \mathbb{R}^{d_{\text{head}} \times d_{\text{model}}}$, $W_O^h \in \mathbb{R}^{d_{\text{model}} \times d_{\text{head}}}$ — матрицы значений и проекции для головы h .

1.4.3 Остаточный поток как коммуникационный канал

Ключевой концептуальной новацией работы является интерпретация **остаточного потока** (residual stream) как единого коммуникационного канала, через который все компоненты модели обмениваются информацией.

В стандартном трансформере [1] вычисление организовано по принципу residual connections:

$$\mathbf{x}^{(l+1)} = \mathbf{x}^{(l)} + \sum_{h=1}^{n_{\text{heads}}} \mathbf{h}^{(l,h)}(\mathbf{x}^{(l)}), \quad (1.15)$$

где $\mathbf{x}^{(l)} \in \mathbb{R}^{T \times d_{\text{model}}}$ — матрица активаций (каждая строка — вектор для одной позиции последовательности длины T), а $\mathbf{h}^{(l,h)}$ — вклад головы h слоя l .

Авторы [2] предлагают переосмыслить эту формулу: остаточный поток $\mathbf{x}^{(l)}$ — это не «активации слоя l », а **общая память**, в которую каждый компонент *читает* информацию и *записывает* свой результат. Благодаря аддитивности residual connections вклады всех компонентов можно анализировать независимо.

Полное разложение по путям. Для attention-only трансформера с L слоями и H головами итоговый вектор активаций разложим как сумму по всем «путям» от входа до выхода:

$$\mathbf{x}^{(L)} = \mathbf{x}^{(0)} + \sum_{l=1}^L \sum_{h=1}^H \mathbf{h}^{(l,h)}(\mathbf{x}^{(l-1)}), \quad (1.16)$$

где $\mathbf{x}^{(0)} = \mathbf{e}_{\text{tok}} + \mathbf{p}_{\text{pos}}$ — сумма токенового и позиционного эмбедингов.

Это разложение нетривиально: оно позволяет *атрибутировать* итоговое предсказание конкретным компонентам и анализировать, какой «путь» через модель несёт ту или иную информацию.

1.4.4 Головы внимания: QK- и OV-цепи

Центральный математический результат работы — факторизация головы внимания на две независимые **цепи**: маршрутизирующую (QK) и трансформирующую (OV).

Стандартная формула головы внимания. Для позиции t и головы h вычисление состоит из двух шагов.

Шаг 1: вычисление паттерна внимания — матрицы $A^h \in \mathbb{R}^{T \times T}$, где элемент $A^h[t, s]$ отражает, насколько позиция t «внимает» позиции s :

$$A^h = \text{softmax} \left(\frac{\mathbf{x} (W_Q^h)^\top W_K^h \mathbf{x}^\top}{\sqrt{d_{\text{head}}}} \right). \quad (1.17)$$

Шаг 2: вычисление вклада головы в остаточный поток:

$$\mathbf{h}^h(\mathbf{x}) = A^h \cdot \mathbf{x} W_V^h W_O^h. \quad (1.18)$$

Факторизация на QK и OV. Введём два **составных матричных произведения**:

QK-цепь (routing circuit):

$$W_{QK}^h = (W_Q^h)^\top W_K^h \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}. \quad (1.19)$$

Матрица W_{QK}^h полностью определяет *паттерн внимания*: значение $\mathbf{x}[t]^\top W_{QK}^h \mathbf{x}[s]$ определяет, насколько позиция t должна внимать позиции s . Иными словами, QK-цепь отвечает на вопрос «куда смотреть?».

OV-цепь (value circuit):

$$W_{OV}^h = W_V^h W_O^h \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}. \quad (1.20)$$

Матрица W_{OV}^h определяет *трансформацию содержимого*: когда голова считала информацию из позиции s , в поток записывается $\mathbf{x}[s] \cdot W_{OV}^h$. OV-цепь отвечает на вопрос «что скопировать из найденной позиции?».

Итоговая формула через QK и OV. Подставляя (1.19) и (1.20) в (1.18), получаем:

$$\mathbf{h}^h(\mathbf{x}) = \text{softmax}\left(\frac{\mathbf{x} W_{QK}^h \mathbf{x}^\top}{\sqrt{d_{\text{head}}}}\right) \cdot \mathbf{x} W_{OV}^h. \quad (1.21)$$

Ключевое свойство: QK- и OV-цепи **независимы**. Голова может внимать к позиции s (определяется W_{QK}^h) и при этом трансформировать содержимое s произвольным образом (определяется W_{OV}^h).

Низкоранговость. Поскольку $W_Q^h, W_K^h, W_V^h \in \mathbb{R}^{d_{\text{head}} \times d_{\text{model}}}$, произведения W_{QK}^h и W_{OV}^h являются матрицами *ранга не выше* d_{head} :

$$\text{rank}(W_{QK}^h) \leq d_{\text{head}}, \quad \text{rank}(W_{OV}^h) \leq d_{\text{head}}. \quad (1.22)$$

При типичных значениях $d_{\text{model}} = 768$ и $d_{\text{head}} = 64$ ранг составляет лишь $\approx 8\%$ от полного ранга, что означает, что каждая голова реализует сильно сжатое, низкомерное преобразование.

1.4.5 Нулевой трансформер (zero-layer)

Простейший случай — трансформер *без* слоёв внимания — позволяет понять, что достижимо при «прямом» пути от токена до предсказания.

Вычисление. Единственный активный путь: входной токен t эмбеддируется, затем проецируется в логиты через унэмбеддинг:

$$\text{logits}(t) = W_E[t] \cdot W_U = W_E[t] \cdot W_E^\top. \quad (1.23)$$

Интерпретация. Произведение $W_E \cdot W_E^\top \in \mathbb{R}^{|V| \times |V|}$ — это матрица косинусного сходства между токенами в пространстве эмбединга. Логит для токена s при входе t равен $\mathbf{w}_t \cdot \mathbf{w}_s^\top$, то есть насколько эмбединги токенов t и s похожи.

Ограничения. Нулевой трансформер может реализовать только **биграммную статистику**: предсказание следующего токена зависит лишь от текущего, но не от контекста. Это объясняет, почему глубина (число слоёв) критична: каждый слой добавляет контекстно-зависимую обработку.

1.4.6 Однослойный трансформер

Добавление одного слоя внимания с H головами кардинально расширяет класс реализуемых функций.

Полное разложение логитов. Итоговые логиты для позиции t раскладываются в сумму:

$$\text{logits}(t) = \underbrace{W_E[x_t] \cdot W_U}_{\text{прямой путь}} + \sum_{h=1}^H \sum_{s=1}^T A^h[t, s] \cdot \underbrace{W_E[x_s] \cdot W_{OV}^h \cdot W_U}_{\text{вклад позиции } s \text{ через голову } h}. \quad (1.24)$$

Введём виртуальную матрицу OV в пространстве словаря:

$$M^h = W_E \cdot W_{OV}^h \cdot W_U \in \mathbb{R}^{|V| \times |V|}. \quad (1.25)$$

Элемент $M^h[s, c]$ отвечает на вопрос: «насколько наблюдение токена s в исходной позиции повышает (или понижает) вероятность предсказания токена c через голову h ?». Это позволяет анализировать OV -цепь непосредственно в пространстве токенов.

Skip-trigrams. Формула (1.24) показывает, что однослойный трансформер реализует **skip-trigrams**: для каждой головы h и пары токенов (s, t) (которые могут находиться на произвольном расстоянии) существует «таблица предсказаний», зависящая от x_s и x_t через QK -цепь.

Формально, если QK-цепь устроена так, что $A^h[t, s] \approx 1$ только при $x_t = B$ и $x_s = A$ (то есть голова внимает к токenu A из позиции B), то голова вносит вклад $M^h[A, \cdot]$ в логиты позиции t . Это реализует паттерн: «при наличии токена A на любой предшествующей позиции и токена B в текущей позиции — предсказать токен C ».

Анализ OV-цепи через собственные значения. Для анализа того, какую информацию голова «перемещает», авторы изучают матрицу M^h через её собственное разложение:

- **Положительные собственные значения:** соответствующие токены получают *буст* логитов — голова их «копирует» и усиливает;
- **Отрицательные собственные значения:** соответствующие токены *подавляются* — голова активно снижает их вероятность;
- **Малые собственные значения:** токены нейтральны для данной головы.

Собственный вектор $\mathbf{v}$ с большим положительным собственным значением соответствует набору токенов, которые голова «предпочитает копировать» в любой контекст, откуда она была направлена. Это даёт прямую интерпретацию функции головы без необходимости перебирать отдельные входные примеры.

1.4.7 Двухслойные трансформеры: типы композиции

При наличии двух слоёв внимания головы второго слоя могут использовать выходы голов первого слоя, «читая» их из остаточного потока. Авторы выделяют три типа такой **композиции**.

После первого слоя остаточный поток равен:

$$\mathbf{x}^{(1)}[s] = \mathbf{x}^{(0)}[s] + \sum_{h_1} \mathbf{h}^{(1, h_1)}(\mathbf{x}^{(0)})[s]. \quad (1.26)$$

Когда голова h_2 второго слоя вычисляет свой вклад, она читает из $\mathbf{x}^{(1)}$, и разность $\mathbf{x}^{(1)} - \mathbf{x}^{(0)}$ содержит записи голов первого слоя.

Q-композиция

В Q-композиции **запрос** (query) головы h_2 зависит от выхода головы h_1 .

Часть паттерна внимания головы h_2 , обусловленная Q-композицией:

$$A_{Q\text{-comp}}^{h_2}[t, s] \propto \mathbf{h}^{(1, h_1)}(\mathbf{x}^{(0)})[t] \cdot W_{QK}^{h_2} \cdot \mathbf{x}^{(0)}[s]^\top. \quad (1.27)$$

Смысл: голова h_2 «спрашивает» (Q) о том, что голова h_1 уже записала в поток на позиции t . То, что именно ищет h_2 , определяется предыдущими вычислениями.

K-композиция

В K-композиции **ключ** (key) головы h_2 зависит от выхода головы h_1 .

$$A_{K\text{-comp}}^{h_2}[t, s] \propto \mathbf{x}^{(0)}[t] \cdot W_{QK}^{h_2} \cdot \mathbf{h}^{(1, h_1)}(\mathbf{x}^{(0)})[s]^\top. \quad (1.28)$$

Эффективная «виртуальная QK-матрица» для этого пути:

$$W_{QK}^{h_2 \leftarrow h_1} = W_{QK}^{h_2} \cdot W_{OV}^{h_1}. \quad (1.29)$$

Смысл: голова h_2 ищет в контексте позиции с определёнными свойствами *после того, как голова h_1 уже преобразовала их содержимое*. Это позволяет h_2 «реагировать» не на сами токены, а на семантические признаки, записанные h_1 .

V-композиция

В V-композиции **значение** (value), которое голова h_2 копирует, содержит выход головы h_1 .

Эффективная OV-матрица для этого пути:

$$W_{OV}^{h_2 \leftarrow h_1} = W_{OV}^{h_1} \cdot W_{OV}^{h_2}. \quad (1.30)$$

Смысл: голова h_2 берёт информацию, *уже преобразованную* головой h_1 , и применяет к ней своё собственное OV-преобразование. Это позволяет

реализовывать двухшаговые «конвейерные» вычисления.

Значение трёх типов композиции. Каждый тип композиции порождает новый «виртуальный двухголовный путь» через модель. Авторы показывают, что эти пути допускают точную матричную запись и могут быть проанализированы через собственные разложения, что делает двухслойные модели полностью трактабельными.

1.4.8 Индукционные головы

Наиболее важный эмпирический результат работы [2] — идентификация механизма **индукционных голов** (induction heads). Это первый конкретный алгоритм, выявленный в реальных трансформерах, который объясняет способность к **контекстному обучению** (in-context learning, ICL).

Наблюдение: паттерн $[A][B] \dots [A] \rightarrow [B]$

Авторы обнаружили, что двухслойные attention-only трансформеры при тестировании на последовательностях вида $[\dots A B \dots A ?]$ с высокой вероятностью предсказывают B на месте $?$. Иными словами, если в контексте встречалась пара токенов $[A][B]$, то при повторном появлении $[A]$ модель «помнит», какой токен следовал за ним.

Это базовый вид контекстного обучения: модель *извлекает паттерн из примеров* в собственном контексте, не используя никаких параметрических знаний о конкретных токенах.

Механизм: два взаимодействующих компонента

Реализация паттерна требует согласованной работы двух компонентов.

Компонент 1: «Голова предыдущего токена» (previous-token head).

Это голова первого слоя с QK-паттерном:

$$A^{h_1}[t, s] \approx \begin{cases} 1, & s = t - 1, \\ 0, & \text{иначе.} \end{cases} \quad (1.31)$$

OV-цепь этой головы приближённо тождественна: $W_{OV}^{h_1} \approx I_{d_{\text{model}}}$.

Эффект: позиция t получает в свой остаточный поток **информацию о токене** x_{t-1} . После первого слоя: $\mathbf{x}^{(1)}[t] \approx \mathbf{x}^{(0)}[t] + \mathbf{x}^{(0)}[t - 1]$.

Компонент 2: «Индукционная голова» (induction head). Это голова второго слоя, использующая **К-композицию** с предыдущей головой.

Ключ (key) индукционной головы вычисляется из $\mathbf{x}^{(1)}[s]$, которое содержит $\mathbf{x}^{(0)}[s - 1]$ (запись от первой головы). Запрос (query) вычисляется из $\mathbf{x}^{(1)}[t]$, содержащего $\mathbf{x}^{(0)}[t]$ (текущий токен).

Эффективная QK-матрица через (1.29):

$$W_{QK}^{h_2 \leftarrow h_1} = W_{QK}^{h_2} \cdot W_{OV}^{h_1} \approx W_{QK}^{h_2}. \quad (1.32)$$

Паттерн внимания:

$$A^{h_2}[t, s] \propto \exp\left(\frac{\mathbf{x}^{(0)}[t]^\top W_{QK}^{h_2} \mathbf{x}^{(0)}[s - 1]}{\sqrt{d_{\text{head}}}}\right), \quad (1.33)$$

то есть позиция t внимает к позиции s , если $x[s - 1]$ **похож на** $x[t]$ — то есть если *токен, стоявший до s , совпадает с текущим токеном t .*

Полный алгоритм пошагово

Рассмотрим последовательность $[\dots, A, B, \dots, A, ?]$, где знак $?$ обозначает текущую позицию t .

1. **Первый слой:** голова предыдущего токена записывает в каждую позицию s идентификатор токена x_{s-1} :

$$\mathbf{x}^{(1)}[s] \approx \mathbf{x}^{(0)}[s] + \mathbf{x}^{(0)}[s - 1].$$

Для первого вхождения A в позиции p : $\mathbf{x}^{(1)}[p+1]$ содержит информацию о A , а также само содержимое B .

2. **Второй слой:** индукционная голова для позиции t (текущее содержимое: A в позиции t) ищет, где ключ равен A :

$$A^{h_2}[t, s] \text{ максимально при } x_{s-1} = A,$$

то есть при $s = p + 1$ (позиция сразу после первого A).

3. **Копирование:** OV-цепь индукционной головы копирует $\mathbf{x}^{(1)}[p+1]$ (содержащее B) в позицию t :

$$\Delta \mathbf{x}^{(2)}[t] = A^{h_2}[t, p+1] \cdot \mathbf{x}^{(1)}[p+1] \cdot W_{OV}^{h_2}.$$

4. **Предсказание:** через унэмбединг повышается логит токена B .

Математическое выражение для буста логита. Объединяя все пути, логит-буст для токена $c = B$ через полный двухголовный путь:

$$\Delta \text{logit}(c) \propto W_E[B] \cdot W_{OV}^{h_2} \cdot W_{OV}^{h_1} \cdot W_U[B]^\top \cdot \underbrace{A^{h_1}[t, t-1] \cdot A^{h_2}[t, p+1]}_{\approx 1}, \quad (1.34)$$

что пропорционально произведению OV-матриц обеих голов.

Экспериментальная верификация

Авторы проверяют гипотезу об индукционных головах тремя независимыми методами.

- **Визуализация паттернов внимания:** на последовательностях с повторяющимися подпоследовательностями паттерн A^{h_2} показывает характерный «диагональный сдвиг на 1» — точно как предсказывает механизм (1.33).
- **Тест на составных последовательностях:** при удалении (ablation) головы предыдущего токена индукционная способность исчезает, а

потери на повторяющихся последовательностях резко возрастают. Это подтверждает, что обе головы необходимы.

- **Анализ $W_{OV}^{h_1}$:** собственные значения OV-матрицы предыдущей головы сконцентрированы около 1, то есть она действительно реализует приближённое тождественное преобразование — именно то, что требуется механизму.

1.4.9 Фазовые переходы и контекстное обучение

Одним из наиболее удивительных наблюдений работы [2] является то, что индукционные головы формируются в процессе обучения **резко** — через фазовый переход.

Феномен фазового перехода. При обучении двухслойного attention-only трансформера на языковом моделировании потери (cross-entropy loss) демонстрируют не монотонное убывание, а **ступенчатое снижение**: на определённом шаге обучения происходит резкий скачок улучшения, после которого потери остаются стабильно ниже.

Корреляция с ICL. Авторы измеряют in-context learning ability независимо — способность предсказывать B в паттерне $[A][B] \dots [A]$ — и обнаруживают, что:

- *До* перехода: ICL-способность слаба; модель игнорирует повторяющиеся паттерны в контексте;
- *После* перехода: ICL-способность резко возрастает одновременно с формированием индукционных голов.

Интерпретация. Фазовый переход означает, что индукционные головы не формируются «постепенно» — это **дискретное эмерджентное явление**: сеть внезапно «открывает» схему из двух взаимодействующих голов как кооперативное решение. До этого момента ни одна из голов в отдельности не имеет этой функции.

Этот результат имеет принципиальное значение для понимания ICL: авторы выдвигают гипотезу, что *контекстное обучение в трансформерах в значительной мере реализуется через механизм индукционных голов*, особенно на ранних слоях. Хотя в глубоких моделях существуют более сложные варианты этого механизма, индукционные головы остаются базовым строительным блоком.

1.4.10 Выводы по методу

Работа «A Mathematical Framework for Transformer Circuits» [2] вносит следующий вклад в механистическую интерпретируемость:

1. **Остаточный поток как коммуникационный канал:** аддитивная структура residual connections позволяет независимо анализировать вклад каждого компонента модели (1.16), атрибутируя итоговое предсказание конкретным путям.
2. **QK/OV-факторизация:** каждая голова внимания разложима на независимые цепи маршрутизации (QK) и трансформации (OV), что даёт двойственную интерпретацию — «куда смотреть» и «что копировать» — без взаимного смешения этих ролей.
3. **Матричный язык для анализа цепей:** виртуальные матрицы $M^h = W_E \cdot W_{OV}^h \cdot W_U$ и составные выражения для K-/Q-/V-композиции (1.29)–(1.30) позволяют анализировать многоголовные взаимодействия как единые матричные операции.
4. **Индукционные головы:** идентифицирован первый конкретный алгоритм в трансформерах — механизм $[A][B] \dots [A] \rightarrow [B]$, реализуемый через K-композицию двух голов и объясняющий базовое контекстное обучение.
5. **Фазовые переходы:** индукционные головы формируются как дискретное эмерджентное явление в ходе обучения, коррелирующее с резким ростом ICL-способностей.

Ограничения. Метод опирается на упрощения: отсутствие MLP-слоёв, связанные матрицы эмбединга и (для части анализа) линейное внимание. В реальных трансформерах MLP-слои вносят существенный нелинейный вклад, и полный анализ вычислительного графа становится значительно сложнее. Тем не менее принципы остаточного потока, QK/OV-факторизации и понятие цепи применимы и к реальным моделям, что подтверждается последующими работами по circuit tracing и атрибуционным графам.

Заключение

В данной курсовой работе рассмотрена серия из четырёх взаимосвязанных работ, образующих последовательную исследовательскую программу в области механистической интерпретируемости языковых моделей.

Достигнутые результаты.

- Разобран **математический фреймворк трансформерных цепей** [2]: концепция остаточного потока как коммуникационного канала (1.15), QK/OV-факторизация голов внимания (1.19)–(1.20), три типа межслойной композиции (1.27)–(1.30), механизм индукционных голов (1.33) и его связь с фазовым переходом в процессе обучения.
- Изучена теоретическая основа полисемантической нейронов — **гипотеза суперпозиции** [3]: нейронные сети хранят больше признаков, чем имеют нейронов, используя неортогональные направления в пространстве активаций. Показано существование фазового перехода (1.3) и правильных геометрических конфигураций суперпозиции.
- Подробно разобран метод **разреженных автокодировщиков** [4]: архитектура SAE (1.6)–(1.7), функция потерь (1.9) с L1-регуляризацией, система оценки признаков через ручную и автоматизированную интерпретируемость, а также каузальная верификация через feature steering.
- Проанализировано **масштабирование метода** [5]: переход к TopK-разреженности (1.11), законы масштабирования (1.13), обнаружение признаков безопасности и мультимодальных концептов в Claude 3 Sonnet при размере словаря до 16М признаков.

Значимость подхода. Четыре рассмотренные работы показывают: *механистическая интерпретируемость масштабируемых языковых моделей достижима*. Фреймворк цепей даёт язык для точного описания алгоритмов внутри трансформера; SAE позволяет преобразовать непрозрачные

активации в словарь интерпретируемых признаков, сохраняя точность описания вычислений. Обнаружение признаков, связанных с безопасностью (prompt injection, манипуляция, нежелательный контент), непосредственно применимо для аудита и верификации безопасного поведения моделей.

Перспективы. Среди открытых задач — распространение анализа цепей на полные трансформеры с MLP-слоями, систематическая каузальная верификация признаков, разработка теоретических гарантий восстановления «истинных» признаков и снижение вычислительной стоимости методов для промышленного применения.

Библиографический список

1. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. — 2017. — Т. 30. — URL: <https://arxiv.org/abs/1706.03762>.
2. A Mathematical Framework for Transformer Circuits / N. Elhage [и др.] // Transformer Circuits Thread. — 2021. — URL: <https://transformer-circuits.pub/2021/framework/index.html>.
3. Toy Models of Superposition / N. Elhage [и др.] // Transformer Circuits Thread. — 2022. — URL: https://transformer-circuits.pub/2022/toy_model/index.html.
4. Towards Monosemanticity: Decomposing Language Models With Dictionary Learning / T. Bricken [и др.] // Transformer Circuits Thread. — 2023. — URL: <https://transformer-circuits.pub/2023/monosemantic-features/index.html>.
5. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet / A. Templeton [и др.] // Transformer Circuits Thread. — 2024. — URL: <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>.
6. The Pile: An 800GB Dataset of Diverse Text for Language Modeling / L. Gao [и др.] // arXiv preprint arXiv:2101.00027. — 2020. — URL: <https://arxiv.org/abs/2101.00027>.
7. Olshausen B. A., Field D. J. Sparse Coding with an Overcomplete Basis Set: A Strategy Employed by V1? // Vision Research. — 1997. — Т. 37, № 23. — С. 3311—3325.

Терминологический словарь

Overfitting Переобучение модели.

Regularization Регуляризация.

В Исходные данные экспериментов

В.1 Протоколы

Текст протоколов.

С Листинги кода (фрагменты)

```
import numpy as np
def loss(y_true, y_pred):
    return np.mean((y_true - y_pred)**2)
```